

基于大模型 RAG 微调与增强的智能运维方法

林 白¹ 高锦杰¹ 李宏伟¹

摘 要 针对装备业务数字化、信息化、智能化管理升级的迫切需求,装备业务管理信息系统可运用基于大模型的智能运维方法提升管理效率和水平,采取在开源大模型基础上微调并用专家知识增强的范式。然而大模型垂直领域微调不足以激发知识检索增强效果,需要将大模型微调时的指令与知识检索增强服务时的指令对齐,训练运维指令跟随、运维专业知识融入理解和可行方案生成能力。因此,提出了一种基于大模型 RAG 微调与增强的智能运维方法。实验证明,通过离线 RAG 微调能大幅提升线上大模型知识检索增强的效果。

关键词 智能运维, 大模型, 微调, 知识检索增强

Intelligent Operation and Maintenance Method Based on RAG Fine-tuned and Enhanced LLM

LIN Bai¹ GAO Jin-Jie¹ LI Hong-Wei¹

Abstract In response to the urgent need for upgrading the digitalization, informatization, and intelligent management of equipment business systems, the equipment business management information systems can use intelligent operation and maintenance methods based on large models to improve management efficiency and level, adopting the comprehensive paradigm of fine-tuning and expert knowledge on the basis of the open-source large models. However, specific domain fine-tuning is not sufficient to stimulate the effectiveness of RAG for the LLM. It is necessary to align the instructions in the fine-tuning stage of the LLM with the instructions in the RAG application stage, for training to develop the ability of the LLM to follow the instructions, understand the professional knowledge retrieved and then embedded in context, and generate feasible solutions. Therefore, an intelligent operation and maintenance method based on RAG fine-tuned and enhanced LLM is proposed. Experimental results have shown that offline RAG fine-tuning for the LLM can significantly improve the effectiveness of online RAG application.

Key words AIOps, LLM, Fine-tuning, RAG

0 引言

随着装备业务管理数字化、信息化、

智能化升级需求日益迫切,装备业务管理信息系统可利用大模型手段,解决管理中的精准决策、精准规划、精准部署、精准落实、精准检验问题。鉴于网络负载及复

1. 军事科学院系统工程研究院系统总体研究所 www.isa.net.cn
1. Institute of Systems Engineering Academy of Military Sciences

杂性的提升,保障业务系统的可靠运行变得越来越重要。因此,当业务系统出现异常故障时,快速有效地进行故障定位与恢复具有重要意义。然而,故障定位与恢复是一项艰巨且耗时的任务,需要大量的专家知识检索与理解操作^[1]。故障定位与恢复要求在有限的时间内快速全面地收集分析日志、指标、故障单等信息,并给出正确的处理措施^[2-3]。传统方法中,面对这些巨量信息,运维工程师需要花费大量的时间来检索和分析数据,因此延误了解决事件和恢复系统功能的时机。同时,运维工程师掌握的专业知识往往具有局限性和时限性,这也会阻碍他们从整体上准确理解和解决故障。此外,采集的故障信息本身存在大量噪声,这会进一步增加故障定位与恢复的难度。

典型的人工智能方法可以用来简化数据分析工作,但运维工程师仍然需要在筛选信息、解释数据、识别根因、制订方案方面投入大量的人力工作^[4]。2022 年人工智能大模型方向取得了重大突破,杰森(Jason Wei)等研究发现,当模型达到一定规模时,大模型智力水平出现“涌现”现象^[5],国内外先后发布了一系列先进的大模型,如 OpenAI 公司的生成式预训练转化器(GPT)、清华大学的一般语言模型(GLM)、阿里巴巴公司的通义千问、百度公司的文心一言等,它们的语言理解能力、生成能力和逻辑推理能力达到人类水平。在系统运维和故障解决领域,系统日志记录了各系统或设备的关键状态和异常告警信息,运维人员积累了大量的专业知识和故障分析与解决案例。大语言模型可以解析大体量数据、识别关键信息,并输出简洁全面的内容,显著减轻运维工程师手动筛选巨量故障信息的负担^[6],这为业务系统的故障定位与恢复提

供了一种有效的途径^[7-8]。

大模型要在运维领域落地应用,无须从零训练,只需在开源的大模型基础上利用垂直领域语料进行微调即可^[9]。同时,针对大模型通常存在“幻觉”、专业知识不足的问题,可通过知识检索增强的方法弥补^[10]。将模型参数微调和 RAG 知识检索增强生成两种手段相结合^[11],能够快捷地提高大模型在垂直领域的专业理解和生成能力。

凭借大模型的理解与生成能力实现自动理解日志告警、自动检索专家知识与经验、自动生成解决方案,从而提高智能运维效率和水平。为此提出了一种基于大模型 RAG 微调与增强的智能运维方法^[12]。区别于传统的 RAG 知识检索增强方法,本文事先进行大模型的 RAG 知识检索增强微调以提升大模型的 RAG 上下文理解与生成能力,然后直接从日志异常出发,经过大模型知识检索增强,自动生成运维故障的解决方案。智能运维大模型底座采用清华大学 GLM3-6B^[13],并构造 RAG 运维知识增强问答样本进行了指令监督微调;智能运维系统的日志告警则会自动触发运维大模型搜索报错异常信息、专家知识和案例,通过 RAG 增强生成得到故障解决方案。对实际运维故障处理案例进行专家评估,结果显示 RAG 知识检索增强微调对于基于 RAG 知识增强的大模型运维系统来说是必要的,它能提升大模型在运维领域的专业知识理解与生成能力,大幅提升大模型生成运维方案的可靠性。

1 理论方法

引入基于大模型知识检索微调与增强的智能运维框架(图 1)。大模型检索增

强微调方法是利用预先训练的大语言模型（LLM）并在特定数据集上进行进一步训练的过程；大模型检索增强服务是集成检索能力的 LLM 文本生成方法。大模型智能运维系统由运维大模型底座和运维大模型服务两部分组成，并且在大模型训练阶段采取知识检索增强微调措施来提高大模型服务阶段的知识检索增强能力。

1.1 大模型检索增强微调方法

为了克服传统大模型检索增强生成存在的上下文知识理解与使用程度低的问题，考虑在大模型微调阶段，采用 LLM 大模型辅助生成的方法构造 RAG 知识检索增强微调样本，训练大模型的运维指令跟随、运维专业知识融入理解和可行方案生成能力。




图 1 智能运维系统架构图

1. 微调样本构造

基于历史错误级别的日志异常，通过互联网搜索或知识库检索，收集故障解决知识和案例经验，构造 RAG 检索样本。引入 LLM 大模型通过 Prompt 指令生成最优的参考答案，运维专家进一步修正和标注，构成指令问答对，基于此，构造知识检索增强微调样本示例如下：

Instruction：

你是一个高级运维开发工程师，可以根据报错日志和报错日志相关的专家知识库给出详细的解决方案；如果有多种解决方案的话，将

方案根据可靠性从高到低排序输出；存在多种类似的解决方案，可以对这些方案去重，整理再输出。

错误日志内容如下：

###

1251-Client does not support authentication protocol requested by server; consider upgrading MySQL client

###

报错日志相关的专家知识库，参考如下：

###

专家知识来源 1：

①升级 navicat 驱动; ②把 mysql 用户登录密码加密规则还原成 mysql_native_password。方式②需要 Win+R, 输入 cmd 打开命令行, 进入 MySQL 的 bin 目录, 然后输入 mysql -u root -p, 输入密码登录。按照以下命令修改即可。

```
ALTER USER 'root'@'localhost'
IDENTIFIED BY 'password' PASSWORD EXPIRE
NEVER; #修改加密规则
```

```
ALTER USER 'root'@'localhost'
IDENTIFIED WITH mysql_native_password BY '
password'; #更新一下用户的密码
```

```
FLUSH PRIVILEGES; #刷新权限
```

专家知识来源 2:

方法一

修改 root 加密方式

1. 查看 root 或其他用户信息的加密方式

```
[root@centos7 ~] # mysql -u root -p #
```

登录 mysql

```
mysql> use mysql; # 切换 mysql 数据库
```

```
mysql> select user, plugin from user where
user='root'; #查看 root 的加密方式
```

2. 改变加密方式

```
alter user 'root'@'%' identified with mysql_n-
ative_password by '123456';
```

```
mysql> select user, plugin from user where
user='root';
```

方法二

添加用户, 同时设置登录加密方式为 mysql_native_password, 并且给它远程访问权限, 完成后这个用户也可以访问。

添加远程登录用户

```
CREATE USER 'mjh'@'%' IDENTIFIED
WITH mysql_native_password BY '123456';
GRANT ALL PRIVILEGES ON *.* TO 'mjh'@
'%';
```

###

请根据报错日志相关的专家知识库中的不同知识来源对错误日志提供解决方案

Output:

根据提供的错误日志和专家知识库, 以下是针对 “1251-Client does not support authentication protocol requested by server; consider upgrading MySQL client” 错误的解决方案, 按照可靠性从高到低排序:

方案一: 修改 MySQL 用户密码加密规则 (最高可靠性)

这个方案通常能够解决客户端和服务端认证协议不匹配的问题。

1. 登录到 MySQL 服务器

```
mysql -u root -p
```

输入密码后进入 MySQL 命令行。

2. 切换到 MySQL 数据库

```
use mysql;
```

3. 修改现有用户的加密方式 (如 root 用户)

```
ALTER USER 'root'@'localhost'
IDENTIFIED BY 'password' PASSWORD EXPIRE
NEVER;
```

```
ALTER USER 'root'@'localhost'
IDENTIFIED WITH mysql_native_password BY
'password';
```

这里的 'password' 需要替换为实际的 root 用户密码。

4. 刷新权限

```
FLUSH PRIVILEGES;
```

方案二: 创建新用户使用 mysql_native_password 加密 (次高可靠性)

如果修改现有用户加密方式不可行, 可以创建一个新用户。

登录到 MySQL 服务器上 (步骤同上)。

创建新用户并设置密码和加密方式。

```
CREATE USER 'new_user'@'%' IDENTI-
FIED WITH mysql_native_password BY 'new_
password';
```

这里的 'new_user' 和 'new_password' 需要替换为你想创建的用户名和密码。

给新用户授权

```
GRANT ALL PRIVILEGES ON *.* TO 'new_
user'@'%';
```

```
FLUSH PRIVILEGES;
```

方案三：升级 MySQL 客户端（可靠性取决于具体情况）

如果上述方案都无法解决问题，可以考虑升级 MySQL 客户端。

对于 Navicat 等第三方工具，升级到最新版本。

对于命令行客户端，确保安装了与 MySQL 服务器版本兼容的客户端版本。

注意：

在实际操作中，建议首先尝试方案一和方案二，因为这些操作不需要升级客户端，对现有环境的影响较小。

方案一和方案二本质上是一致的，只是方案一针对现有用户，方案二是创建新用户。在这里，为了避免重复，只列出了两个主要方案，并进行合并和整理。

按照这个优先级排序，应该能够解决大多数认证协议不匹配的问题。如果问题仍然存在，可能需要进一步检查客户端和服务器的配置以及网络连接情况。

2. 高效微调方法

研究表明，大语言模型在针对下游任务进行微调后，权重参数矩阵通常具有很低的本征秩，即高维度的参数矩阵中存在冗余^[14]。由此，研究人员假设模型微调时权重更新的那部分参数矩阵也是低秩的，并提出多种参数高效微调方法。LoRA (Low-Rank Adaptation) 是其中一种典型的高效微调方法，可以在降低模型微调参数量和显存占用的同时，使训练后的模型具有与全量微调相当的性能^[15]。LoRA 模型架构图如图 2 所示。

图中左边部分 W_0 是预训练大模型的参数矩阵，右边部分是 LoRA 增加的可训练权重参数 ΔW ，分为 A 、 B 两个低秩分解矩阵，秩为 r 。其中， A 矩阵使用随机高斯分布进行初始化，维度为 $r \times k$ ，负责将输入数据维度降至 r 维； B 矩阵使用 0 进行初始化，维度为 $d \times r$ ，负责将数据维度




图 2 LoRA 微调模型架构

升至 d 维。LoRA 模型最后的输出为预训练参数部分与可训练参数部分的叠加：

$$h = W_0 x + \Delta W x = W_0 x + B A x \quad (1)$$

LoRA 微调模型降低了微调参数量，且没有引入额外的推理延迟，可以显著改善微调大模型“灾难性遗忘”的问题，是一种高效的参数微调方法。本文选用 LoRA 方法，基于大模型检索增强微调样本对 GLM3-6B 模型进行参数高效微调，构建面向故障定位与恢复领域的基于大模型 RAG 微调与增强的智能运维系统。

1.2 大模型检索增强服务

智能运维系统线上日志异常处理模块会自动触发运维大模型进行分词搜索和向量检索，召回与对应日志故障分析解决密切相关的文档，并综合文档的相关度、质量、有效性等因素对参考文档进行排序。通过 Prompt 指令将最相关的文档资料作为上下文进行大模型 RAG 增强生成，直接得到可靠的解决方案。

2 实验分析

2.1 大模型 RAG 微调分析

为了对基于大模型 RAG 微调与增强的

智能运维方法进行性能分析测试,设计了三个对比模型。第一个模型是没有经过大模型 RAG 微调的原始 GLM3-6B 模型,第二个模型是经过大模型 RAG 微调的 GLM3-6B 模型,第三个模型是经过大模型 RAG 微调与检索增强的 GLM3-6B 模型。使用 OpsEval^[16]中提出的基于人工打分的专家评估 (Expert Evaluation) 方法确定输出信息的流畅性、准确性、证据量等作为本文分析的评判指标,各项分值范围为 0~5,分数越高,模型性能越好。由 3 名运维领域专家对每个模型的 100 条样本数据问答信息进行打分,取全部打分的平均值作为该模型最终得分,实验结果见表 1。

表 1 专家评估结果

模型	专家评估平均分			
	流畅性	准确性	证据量	总分
GLM3-6B	2.98	2.83	2.16	7.97
RAG 微调模型	3.53	3.98	4.14	11.65
RAG 微调与检索增强模型	3.99	4.45	4.51	12.95

表 1 中的 GLM3-6B 表示清华大学发布的原始 GLM3-6B 模型,RAG 微调模型表示经过大模型 RAG 微调的 GLM3-6B 模型,RAG 微调与检索增强模型表示经过大模型 RAG 微调与检索增强的 GLM3-6B 模型。由表 1 可以看出,经过 RAG 微调与检索增强后的 GLM3-6B 模型在流畅性、准确性、证据量方面显著优于原始 GLM3-6B 模型和经过大模型 RAG 微调的 GLM3-6B 模型。这表明 RAG 微调方法可以增强大模型对专业领域业务问答数据的理解和生成能力,生成更流畅、准确的答案,并提供充足的证据。而通过融合知识检索增强方法,可以进一步增强大模型的专业领域知识,生成更加准确且符合业务要求的分析结果。

2.2 线上效果评测

大模型 RAG 微调后对线上日志告警处理提供服务支撑,由报错日志出发,大模型自动检索相关知识和方案进行 RAG 增强,生成故障解决方案。例如,系统报错如下:

```
ERROR Exiting Kafka due to fatal exception
during startup. (kafka. Kafka $ )

kafka. common. InconsistentClusterIdException:
The Cluster ID CaoegNzgQImpR9G-dpg7SQ doesn't
match stored clusterId Some ( HyzBmmDkQi -
K8Ai1XFgiaA ) in meta. properties. The broker is
trying to join the wrong cluster. Configured zoo-
keeper. connect may be wrong.
```

触发大模型处理流程,生成结果如下:

根据提供的错误日志和专家知识库,以下针对 Kafka 启动时遇到的 InconsistentClusterIdException 异常的解决方案,按照可靠性从高到低排序:

方案一:修改 meta. properties 中的 Cluster ID (最高可靠性)

1. 根据错误日志提示,找到 Kafka 的 server. properties 配置文件中的 log. dirs 配置项。
2. 在指定的 log. dirs 路径下,查找 meta. properties 文件。
3. 打开 meta. properties 文件,找到 cluster. id 属性。
4. 将 cluster. id 的值修改为错误提示中的 Cluster ID (即 CaoegNzgQImpR9G-dpg7SQ)。
5. 保存文件并退出编辑器。
6. 重新启动 Kafka 服务。

方案二:清理 Kafka 日志目录 (次高可靠性)

如果方案一无效,或者你不确定如何准确修改 Cluster ID,可以尝试以下步骤:

再次确认 log. dirs 配置项指定的路径。

删除该路径下的所有文件和文件夹。注意,这个操作将删除所有 Kafka 数据,请谨慎操作。

删除完毕后，重新启动 Kafka 服务。

方案三：检查 Kafka 启动脚本和配置文件路径（中等可靠性）

确保启动 Kafka 时使用的是正确的配置文件。

从 Kafka 的根目录运行启动脚本：

```
bin/kafka - server - start.sh config/server.properties
```

确认 zookeeper.connect 配置项是否指向正确的 Zookeeper 集群。

方案四：升级 JDK 版本（最低可靠性）

检查当前的 JDK 版本是否与 Kafka 兼容。

如果 JDK 版本过旧，尝试升级到更高的版本。注意，这应该是最后考虑的解决方案，因为 JDK 升级可能会影响其他服务。

注意：

方案一和方案二是针对错误日志中提到的具体问题的直接解决方案。

方案三和方案四则是一些辅助性的检查和调整，可能在某些特定情况下有所帮助。

在实际操作中，建议首先尝试方案一，因为它直接解决了 Cluster ID 不一致的问题。

根据以上分析，解决方案已经去重并整理输出。如果问题仍然存在，可能需要进一步检查 Kafka 和 Zookeeper 的配置一致性，以及网络连接和防火墙设置。

按照方案指引操作故障恢复成功。

经过对 200 个日志故障解决方案进行验证和评估，结果表明，经过知识增强微调和增强的大模型能提供出色的解决方案，表现在以下方面：

可靠性：大模型生成的解决方案可靠性高，成功解决率达到 95.5%。

效率：大模型自动生成解决方案，大量节省了运维人员的时间，显著提高了故障处理的效率。

可解释性：大模型从专家知识库中提取了多种解决方案，并能识别可靠性高的解决方案，这在实际操作中得到了验证，

第一方案在绝大多数情况下能够解决问题。

3 结束语

通用 LLM 大模型在运维领域快速应用落地采用“业务域微调+知识检索增强”范式。在通用预训练 LLM 大模型基础上进行业务域微调，可选用 LoRA 高效微调方法，拟合业务问答数据特征，建立面向垂直领域的理解和生成能力。知识检索增强能弥补大模型专业领域知识的不足，消除大模型的“幻觉”现象，对垂直领域的可控生成是至关重要的。

本文将离线业务域微调与线上大模型服务中的知识检索增强结合在一起，做对应的知识检索增强微调，训练运维指令跟随、运维专业知识融入理解和可行方案生成能力，能够提升线上知识检索增强的效果。

由日志出发，大模型自动关联查询分析专业知识和专家经验、自动生成解决方案，为智能运维开辟了一条新思路，为端到端故障自愈奠定了基础。

参考文献

- 1 MA M, YIN Z, ZHANG S, et al. Diagnosing root causes of intermittent slow queries in cloud databases [J]. In Proceedings of the VLDB Endowment, 2020, 13 (8): 1176-1189.
- 2 HE S, ZHANG X, HE P, et al. An empirical study of log analysis at microsoft [C] //In Proceedings of the 30th ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering. 2022: 1465-1476.
- 3 GANATRA V, PARAYIL A, GHOSH S, et al. Detection is better than cure: A cloud incidents perspective [C] //In Proceedings of the 31st ACM Joint European Software Engineering Confer-

- ence and Symposium on the Foundations of Software Engineering. 2023: 1891–1902.
- 4 CHEN J, ZHANG S, HE X, et al. How incidental are the incidents? characterizing and prioritizing incidents for large-scale online service systems [C] //In Proceedings of the 35th IEEE/ACM International Conference on Automated Software Engineering. 2020: 373–384.
- 5 WEI J, TAY Y, BOMMASANI R, et al. Emergent Abilities of Large Language Models [J]. Transactions on Machine Learning Research, 2022.
- 6 AHMED T, GHOSH S, BANSAL C, et al. Recommending root-cause and mitigation steps for cloud incidents using large language models [C] //In Proceedings of the 45th International Conference on Software Engineering. 2023: 1737–1749.
- 7 SHETTY M, BANSAL C, UPADHYAYULA S P, et al. Autotsg: learning and synthesis for incident troubleshooting [C] //In Proceedings of the 30th ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering. 2022: 1477–1488.
- 8 JIN P, ZHANG S, MA M, et al. Assess and summarize: Improve outage understanding with large language models [C] //In Proceedings of the 31st ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering. 2023: 1657–1668.
- 9 王婷, 王娜, 崔运鹏, 等. 基于人工智能大模型技术的果蔬农技知识智能问答系统 [J]. 智慧农业 (中英文), 2023, 5 (4): 105–116.
- 10 田永林, 王兴霞, 王雨桐, 等. RAG-PHI: 检索增强生成驱动的平行人与平行智能 [J]. 智能科学与技术学报, 2024, 6 (1): 41–51.
- 11 GUU K, LEE K, TUNG Z, et al. REALM: retrieval-augmented language model pre-training [C] //In Proceedings of the 37th International Conference on Machine Learning. 2020: 3929–3938.
- 12 GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: a survey [EB/OL]. (2024-03-27) [2024-06-05]. <https://arxiv.org/abs/2312.10997>.
- 13 ChatGLM3 [EB/OL]. [2024-06-05]. <https://github.com/THUDM/ChatGLM3>.
- 14 AGHAJANYAN A, ZETTLEMOYER L, GUPTA S, et al. Intrinsic dimensionality explains the effectiveness of language model fine-tuning [C] //In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. 2021: 7319–7328.
- 15 HU E J, SHEN Y, WALLIS P, et al. LoRA: low-rank adaptation of large language models [C] //In Proceedings of the 10th International Conference on Learning Representations. 2022.
- 16 LIU Y, PEI C, XU L, et al. opsEval: a comprehensive task-oriented aiops benchmark for large language models [EB/OL]. (2024-02-16) [2024-06-05]. <https://arxiv.org/abs/2310.07637>.