

DOI: 10.3901/JME.2025.23.058

思维链范式智能运维文本基多模态智能体^{*}

黄金凤¹ 王成城² 何宏亮^{1,3} 王旭⁴ 李奇¹ 杨康定³
王凯² 张飞斌¹ 秦朝烨¹ 褚福磊¹

(1. 清华大学高端装备界面科学与技术全国重点实验室 北京 100084;

2. 机械工业仪器仪表综合技术经济研究所 北京 100055;

3. 频率探索智能科技有限公司江苏有限公司 常州 213162;

4. 智能博弈与决策实验室 北京 100091)

摘要: 提出了一种面向机械设备运维的人工智能架构——思维链范式文本基多模态智能体。首先,针对实际工程应用场景中,难以直接构建“监测数据-故障模式”高质量大规模数据集的问题,建立了“监测信号-数学特征-文本描述-故障模式”思维链式数据集构建思想,进而提出了信号-文本数据生成器驱动的信号转文本(Sig2Txt)模型。其次,制作了机械设备运维领域的高质量专业化文本数据集,并基于指令微调技术和通用大语言模型建立了智能运维专业文本大模型。最后,基于大模型智能体技术有机融合上述模型,以人类专家开展设备运维的思维模式为指引,创建了思维链范式智能运维文本基多模态智能体。测试结果表明,该智能体可实现多模态输入数据-运维决策的全流程思维链式解析和映射,在ISO三级振动分析师测试题上的准确率超过70%,达到人类专家级水平。在工程案例和公开数据组成的多模态数据集“热启动”评测中,相比于现有主流大模型,该模型展现出了更优异的性能。更重要的是,得益于所提出的低成本、高质量多模态思维链式大规模数据集的构建体系,以及“文本基”对于知识的包罗万象、高度凝练和易于解释的天然独特优势,该模型具备可观的拓展性和发展潜力。

关键词: 智能运维; 多模态模型; 大语言模型; 故障诊断; 智能体

中图分类号: TH17

Chain-of-thought Paradigm Text-based Multimodal Intelligent Agent for Equipment Operations and Maintenance

HUANG Jinfeng¹ WANG Chengcheng² HE Hongliang^{1,3} WANG Xu⁴ LI Qi¹
YANG Kangding³ WANG Kai² ZHANG Feibin¹ QIN Zhaoye¹ CHU Fulei¹

(1. Department of Mechanical Engineering, Tsinghua University, Beijing 100084;

2. Standards and Testing Center, Instrumentation Technology and Economy Institute, Beijing 100055;

3. FreqX Intelligence Technology Co., Ltd., Changzhou 213162;

4. Intelligent Game and Decision Lab, Beijing 100091)

Abstract: An artificial intelligence architecture—the chain-of-thought (CoT) paradigm text-based multimodal intelligent agent—for operation and maintenance (O&M) of mechanical equipment is proposed. Firstly, to address the challenge of constructing high-quality, large-scale monitoring data-to-fault mode mapping datasets in real-world engineering applications, a chain-of-thought dataset construction strategy integrating monitoring signals, mathematical features, text descriptions, and fault mode is proposed. Based on this, a signal-to-text (Sig2Txt) model driven by a signal-text data generator is developed. Subsequently, a high-quality specialized textual dataset for O&M in the mechanical equipment domain is created, and an intelligent O&M-specialized large language model is established through instruction fine-tuning on a general large language model. Finally, by organically integrating the above models based on large model intelligent agent technology and guided by the operational thinking patterns of human experts in equipment

^{*} 国家自然科学基金(52305115, 52105109, 52161135101)和中国博士后科学基金(2023M741938)资助项目。20250109 收到初稿, 20250906 收到修改稿

maintenance, a chain-of-thought paradigm text-based multimodal intelligent agent for intelligent O&M is formed. Testing results indicate that this model can achieve chain-of-thought parsing and mapping from multimodal input decision-making, with an accuracy exceeding 70% on ISO Category III vibration analyst test questions, thus reaching expert-level performance. In evaluations with engineering cases and publicly available multimodal datasets, the proposed model outperforms existing mainstream large models. More importantly, owing to the proposed low-cost, high-quality multimodal CoT large-scale dataset construction framework, and the unique advantages of a “text-based” approach in terms of encompassing knowledge, high-level abstraction, and interpretability, the model shows considerable scalability and development potential.

Key words: intelligent operation and maintenance; multimodal model; large language model; fault diagnosis; intelligent agent

0 前言

近年来,随着制造业向自动化、数字化、智能化的方向转型升级,智能制造装备在现代制造业中的应用日益广泛^[1-2]。特别是在高危、高强度和重复性工作的岗位上,“机器换人”的趋势变得尤为显著。然而,设备故障是不可避免的,尤其是在长期且重复的工作环境中,智能制造装备很容易出现性能退化和损坏^[3-6]。因此,迫切需要一种智能化的运维系统。这种系统能够主动监测和预测设备所处的健康状态和潜在故障,提供预知性的维护决策方案,从而有效减少意外停机,降低生产成本,提升生产安全性^[7-8]。

以大数据和深度学习模型为核心组合的人工智能在图像识别、自然语言处理和语音识别等领域取得了显著的应用成效,甚至在很多专业领域已经超越了人类专家级的专业水平。总体而言,这些应用成效的前提条件是具有相应领域的高质量、大规模、带标签的数据集。以引领 2010 年开始的深度学习革命的 ImageNet 大规模图像数据集为例,它包含了超过 1400 万张被手动注释的图像,涵盖了 2 万种标签类别^[9-10]。引领 2022 年开始的生成式大语言模型热潮的 ChatGPT 的文本训练数据集更是高达 45TB^[11-12]。而与之类似的高质量大规模数据集在机械设备运维领域始终难以建立,主要是因为存在以下几方面的挑战。

(1) 机械设备运维所需的高质量监测信号数据难以获取,特别是故障数据相比于健康数据极其稀缺,造成严重的数据不平衡问题。

(2) 监测信号数据的标签注释难度大,由于机械设备状态诊断是非常专业化的工作,对标签注释人员的专业水平要求和培训难度非常高,难以像图像识别等通识领域那样进行低成本、大批量且准确高效地注释标签。

(3) 工程现场机械设备的监测信号原始数据中包含大量噪声,更重要的是原始信号往往是多源多特征分量信号线性叠加甚至是非线性叠加形成的,这使得即使是经过系统性培训的专家级人员也难以准确、快速地直接对原始信号进行注释标签。而人工智能在图像识别领域的成功应用场景(例如 AlphaGo 围棋^[13-14]、视觉自动驾驶^[15-16]),则基本不存在或不需考虑多特征图像叠加的问题,就像人类视觉没有透视能力。而且大部分场景下非专业人员就可以直接辨识原始图像并进行准确地标签注释。

概括而言,无论是学术界还是工业界,目前都不具备构建监测信号-故障标签直接匹配的高质量、大规模数据集的条件。这直接导致数据驱动的人工智能技术在机械设备运维领域始终难以取得预期的应用成效,在准确性、可靠性和泛化性等关键性能指标方面都难以满足工程实际要求。

为了从根本上解决这些问题,本文另辟蹊径,以避开传统智能诊断范式中的监测信号-故障模式“黑箱式”数据集为出发点,以人类专家开展设备运维的思维模式(监测信号-信号数学特征+设备物理信息-先验知识-故障模式-维护决策)为指引,提出了思维链范式智能运维数据集架构及文本基多模态智能体。

“文本”是指包含人类自然语言、数学公式和计算机程序代码在内的符号数据系统。相比于监测信号等其他模态数据,文本包含以下优点:①几乎所有的人类知识和信息,都可以用文本进行准确、完整地表述;换言之,不论是通识领域还是专业领域的知识或信息,都有大规模的文本数据;②包括专业书籍、学术论文、行业报告、国家标准、计算机代码等等在内的各专业领域文本是高质量的大规模数据,而且不存在监测信号等其他模态数据的多特征叠加问题。此外,相比于监测信号等其他模态数

据, 文本数据可以相对低本地整理、制作为比肩于图像数据集 ImageNet 的大规模高质量含标签文本数据集。近年来, 依托于大规模文本数据集和大规模模型参数, 采用“预训练+微调”范式^[17-18]的大语言模型(Large language model, LLM)^[19-21]出现了“涌现”能力^[22], 被普遍认为具备实现通用人工智能(Artificial general intelligence, AGI)的潜力^[23]。

当然, 仅仅是由文本数据集训练的大语言模型是不够的, 因为机械设备运维的监测数据是振动信号、声音信号或电流信号等非文本模态数据。也就是说, 用单一的文本模态的数据训练的大语言模型无法直接理解和解析原始的监测数据。因此, 还需要建立监测数据-文本数据之间的映射机制, 形成文本基多模态解析能力。为此, 本文还研究了信号转文本(Signal-to-text, Sig2Txt)模型的构建方法, 提出了两种技术路线。第一种路线是基于先验算法知识的 Sig2Txt, 第二种路线是信号-文本数据集生成器驱动的生成式预训练 Sig2Txt 模型。进一步地, 基于智能体技术有机融合设备运维专业文本大模型和信号转文本模型, 形成了“监测信号-数学特征-文本描述-故障模式”的低成本、高质量、大规模数据集构建渠道, 建立了思维链范式文本基多模态智能体架构, 为大数据驱动的机械设备智能运维的基础设施构建提供了一个切实可行的新路线。

1 信号转文本模型(Sig2Txt)

1.1 监测信号数学特征的文本描述

在人类专家开展机械设备运维的技术工作流程中, 首要的工作是对监测信号的数学特征进行精细化的解析。具体而言, 根据机理知识和实践经验, 利用信号处理技术从监测信号中解析出状态评估、故障诊断、故障预测或维护决策所需的数学特征, 并以结构化或非结构化文本的形式进行描述。本文所提出的信号转文本模型(Sig2Txt)本质上是监测信号-数学特征-文本描述的转换器。从实现方式上, 主要有基于先验算法知识的和基于预训练多模态大模型的 Sig2Txt 这两种技术路线, 如图 1 所示。本节以振动信号分析为例, 论述本文所提出的 Sig2Txt 的构建原理和过程。

在面向机械设备运维的振动分析领域, 所需提取的信号数学特征包含不同的类型。按照特征域划分, 主要包括时域特征、频谱特征、阶次谱特征、

包络谱特征和循环谱特征等。按照特征性质划分, 主要包括谱参数特征、统计特征、非线性特征等。按照特征用途划分, 主要包括状态监测特征、故障诊断特征、寿命预测特征等。




图 1 Sig2Txt 的两种技术路线(灰色区域: 基于先验算法知识的 Sig2Txt; 白色区域: 基于预训练大模型的 Sig2Txt)

需要强调的是, 在人类专家进行振动信号分析的思维过程中, 谱参数特征(时域波形的周期、幅值、相位和轴心轨迹等, 幅值谱、阶次谱、循环谱和包络谱中的基频及其倍频谐波、载波频率、边频带、离散谱线等)是故障诊断的必备特征, 因为它们是故障模式和故障部位的特异性指标。而统计特征(如均方根、峭度等)一般是状态监测指标, 也就是用于异常检测; 它们一般无法直接用于故障诊断, 因为它们与故障模式和故障部位没有特异性关系。换言之, 监测信号的统计特征或非线性特征一般是故障模式的必要条件而非充分条件。以典型故障模式——滚动轴承局部缺陷故障为例, 滚动轴承故障会导致峭度指标升高, 但是峭度指标升高不一定就是出现了滚动轴承故障。

在很长一段时期内, 由于监测信号统计特征易于计算, 而且不需要设备和零部件的结构和运行参数等物理信息作为计算条件, 因此被大量的用于数据驱动的智能诊断模型和算法相关研究中。然而, 由于这些统计特征与故障模式之间的非特异性关系, 人工智能模型从根源上就难以学习到真正的“故障特征”。也就难以具备实用性强的拓展性和迁移性。

因此, 在本文所建立的思维链架构中, 是以监测信号的谱参数特征为核心, 以统计特征和非线性

特征等为辅助，作为 Sig2Txt 模型的构建思路。

1.2 信号分解算法

将振动信号转换为文本描述的一个关键驱动因素是使其可以由大语言模型理解，从而能够执行多样化和可定制的下流任务。当前大语言模型作为智能助理，能够模仿人类认知。其显示出了可靠的单步推断能力，并在有效的提示工程策略指导下显示出复杂的多步推理潜力。大语言模型的熟练程度源于广泛的训练数据集，包括通用和专业知识。此外，Transformer^[24]架构增强了它们组合泛化和符号推理的能力。通过自注意力机制，大语言模型善于将上下文联系起来，追踪逻辑进程，并得出连贯结论。

在实际工程应用中，物理设备通常表现出跨越多个维度的复杂数据特征，故障数据在不同的时间尺度上会表现出不同的行为和特征，而且还包含噪声等多源干扰成分。一种能够准确提取复杂多源激励信号数据中的有用数学特征的信号处理算法是提高诊断结果和运维决策准确率的必要前提。这就有必要在“信号-文本”模态转换过程中开发一个信号分解算法模块，以提取和分析设备监测信号中的数据特征，从而确保从原始信号到连贯文本描述的转化即准确又高效。实际工程应用中，监测数据往往是多传感多源激励信号，而且故障模式识别往往需要融合多传感信号之间的耦合数学特征。多传感信号的融合处理可以转化为典型的高阶张量分析问题。作者在近期研究中提出了柔性张量积及相应的分解算法体系^[25-26]。本文在此基础上，进一步发展出第三类柔性张量奇异谱分解算法，用于 Sig2Txt 模型架构中。柔性张量积定义了任意阶张量之间的乘法运算：

定义 1(柔性张量积)：张量 $\mathbf{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3 \times \dots \times I_m}$ 与张量 $\mathbf{Y} \in \mathbb{R}^{J_1 \times J_2 \times J_3 \times \dots \times J_n}$ 的乘积记为^[25]

$$(\mathbf{X} \times_{o, \langle p, q \rangle} \mathbf{Y})_{k_1 k_2 \dots k_{m+n-2o}} = \sum_{s_1=1}^{S_1} \dots \sum_{s_o=1}^{S_o} \mathbf{X}_{k_1 \bar{\Delta}_x^p} \mathbf{Y}_{\bar{\Delta}_y^q k_{m+n-2o}} \quad (1)$$

其中

$$\begin{cases} \bar{\Delta}_x^p \triangleq s_1 \dots s_o k_2 \dots k_{m-o}, S_o = I_{o+1} & p=1 \\ \bar{\Delta}_x^p \triangleq k_2 \dots k_{m-o} s_o \dots s_1, S_o = I_{m-o+1} & p=2 \\ \bar{\Delta}_y^q \triangleq s_1 \dots s_o k_{m-o+1} \dots k_{m+n-2o-1}, S_o = J_o & q=1 \\ \bar{\Delta}_y^q \triangleq k_{m-o+1} \dots k_{m+n-2o-1} s_o \dots s_1, S_o = J_{n-o} & q=2 \end{cases} \quad (2)$$

式中， $\langle p, q \rangle$ 中的 p 和 q 分别表示张量 $\mathbf{X}$ 和张量 $\mathbf{Y}$ 中参与柔性张量积的阶数顺序，‘1’表示正序，‘2’表示逆序； $o=1, 2, \dots, \min(m, n)-1$ 。

根据柔性张量积的定义，本文推导出了第三类柔性张量奇异值分解：

定义 2(第三类柔性张量奇异值分解)：对于三阶张量 $\mathbf{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ ，其第三类柔性张量奇异值分解可表示为

$$\mathbf{X}_{I_1 \times I_2 \times I_3} = \mathbf{U}_{I_1 \times I_2 \times I_2 \times I_1} \times_{2, \langle 2, 1 \rangle} \mathbf{S}_{I_1 \times I_2 \times I_3} \times_{1, \langle 2, 1 \rangle} \mathbf{V}_{I_3 \times I_3}^T \quad (3)$$

算法的计算过程如下。

输入： $I_1 \times I_2 \times I_3$ 的张量 $\mathbf{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$

$\mathbf{D} = \text{tenmat}(\mathbf{X}) \in \mathbb{R}^{I_1 I_2 \times I_3}$

$[\mathbf{U}, \mathbf{S}, \mathbf{V}^T] = \text{SVD}[\mathbf{D}]$

$\mathbf{U} = \text{ten}(\mathbf{U})$;

$\mathbf{S} = \text{ten}(\mathbf{S})$;

$\mathbf{V}^T = \text{ten}(\mathbf{V}^T)$;

输出： $\mathbf{U} \in \mathbb{R}^{I_1 \times I_2 \times I_2 \times I_1}$ ， $\mathbf{S} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ ， $\mathbf{V} \in \mathbb{R}^{I_3 \times I_3}$

其中， tenmat 表示张量的展开， ten 表示矩阵的张量化，它们互为逆过程。

张量奇异谱分解是以张量奇异值分解为核心的，一种自适应迭代分解算法，主要包含轨迹张量构建、张量奇异值分解、分量信号筛选、残余迭代和迭代终止等步骤^[25]。对于待分析的多传感信号，使用柔性张量奇异谱分解算法对信号进行预处理，是 Sig2Txt 模型的重要组成部分。

1.3 基于先验算法知识的信号转文本模型(PAK-Sig2Txt)

如图 1 所示，基于先验算法知识的 Sig2Txt 包含以下主要步骤：首先采用 1.2 节中的信号分解算法对原始复合信号数据进行处理以获得各分量信号，然后从分量信号中提取出以谱参数特征为核心的数学特征。最后，采用文本生成规则自主生成数学特征的文本化描述

$$f_{\text{Temp}}^{\text{sig} \rightarrow \text{text}}(\mathbf{S}) = \mathbf{D} \quad (4)$$

其中， $f_{\text{Temp}}^{\text{sig} \rightarrow \text{text}}$ 表示变换函数，它接收信号数据作为输入，提供文本描述作为输出。其中 Temp 表示文本描述模板， $\mathbf{D}$ 表示最终的文本描述。以设备运维思维链为指引，本文构建的文本描述模板包括对信号数学特征的定量和定性的描述。其步骤和描述内容如图 2 所示。具体来说，包含总分总形式的 4 个模块：

(1) 定性描述信号类型和组成特性，主要包含信号单元和信号算子；

(2) 定量描述信号时域波形的周期、幅值、相位等谱参数特征，以及统计指标、非线性特征指标等时域特征；

(3) 定量描述信号的基频及谐波、载波频率、

边频带等谱参数特征, 以及频谱统计指标等频域特征;

(4) 定性描述信号时域和频域的对应关系。

总体而言, PAK-Sig2Txt 是利用先验的信号处理技术和设备运维专业领域知识, 结合机理规则、算法逻辑实现对监测信号中特定数学特征的量化提取以及文本化描述。它的优势主要包括: ①不需要大规模训练数据, 可实现快速部署; ②全流程有明确的数学公式和逻辑规则, 开发成本相对较低, 输出结果可靠且易于溯源性解释; ③可实现监测信号的谱参数特征等复杂数学特征的精准提取及文本化表征, 为故障推理提供核心支撑。它的劣势则主要包括: ①仅支持时序向量形式的数据作为输入进行信号的文本化描述输出。②仅支持信号至文本的单向编译, 不支持双向互译, 通用性和扩展性较低。③对信号宏观定性特征的非结构化文本化表征能力较弱。




图2 振动信号文本描述步骤

1.4 基于多模态大模型的信号转本文模型(MLM-Sig2Txt)

本小节论述第二种信号转本文技术路线: MLM-Sig2Txt。如图 1 所示, 该模型包含数据编码器、插值层和大语言模型, 并使用低秩适应技术(LoRA)对编码器和语言模型进行微调。该模型的核心瓶颈是训练和微调数据的数量和质量。为此, 本文提出了信号-文本数据集生成器, 可低成本、高质量的制作大规模“信号数据-数学特征-文本描述”问

答对组 $G=(X_s, X_{qi}, X_{ai})$, 用于训练和优化 MLM-Sig2Txt 大模型, 从而提高其识别和提取监测信号谱参数等数学特征的性能。

图 3 所示为信号-文本数据集生成器框架。该框架主要包含信号单元、信号算子、随机参数、信号函数、复合信号、信号数据和文本描述。




图3 “信号数据-数学特征-文本描述”问答对生成框架

(1) 信号单元

信号单元是指构成信号函数的基本信号类型, 例如, 简谐信号、冲击衰减信号、小波信号、非平稳随机信号和平稳随机信号等。随机信号是指时间序列在每个时刻的取值是随机变量。随机信号可以用概率分布特性进行统计性描述。根据 k 阶矩是否与时间相关, 随机信号可分为非平稳随机信号和平稳随机信号。若对所有整数 $1 \leq k \leq n$, 以及所有 $\{\tau, t_1, \dots, t_k\} \in \mathbf{R}$, 随机信号满足^[27]:

$$\mu(t_1, \dots, t_k) = \mu(t_1 + \tau, \dots, t_k + \tau) \quad (5)$$

则称之为 n 阶平稳信号, 其中 $\mu(t_1, \dots, t_k)$ 表示随机信号的 k 阶矩。进一步地, 可以通过调整随机信号的 k 阶矩时变性来模拟不同的非平稳随机信号源。比如:

$$x_{cs1}(t) = ae^{j(2\pi ft + \theta)} + n(t) \quad (6)$$

是一阶循环平稳随机信号, 其中, $n(t)$ 为具有零均值的平稳随机噪声, θ 为常数。

$$x_{cs2}(t) = [1 + ae^{j(2\pi ft + \theta)}]n(t) \quad (7)$$

是二阶循环平稳随机信号。

(2) 信号算子

信号算子是指信号单元之间进行运算的方式, 可用于模拟和表征信号的线性/非线性叠加和特征。例如信号单元相加、相减、相乘、卷积、积分、幂运算等等。

(3) 随机参数

随机参数是指信号单元和信号算子中的可变参数, 例如, 信号单元中可变参数包括: 简谐信号中的振幅、频率和相位; 冲击衰减信号中的冲击幅度、

频率和衰减时间常数;小波信号中的尺度伸缩参数,时间平移参数。信号算子中可变参数包括信号算子的个数或比例系数等。

(4) 信号函数

信号函数是指由信号单元、信号算子和随机参数构成的信号数学表达式,它包含了描述一个信号所需的所有量化参数,下面给出几种典型信号的函数表达式:

多倍频谐波信号:

$$y_1(t) = \sum_{i=1}^N A_i \sin(2\pi f_i t + \varphi_i) \quad (8)$$

式中, φ_i 为初始相位, A_i 为信号的振幅, f 为频率, t 是时间, N 为谐波总个数。

非倍频多简谐波信号:

$$y_2(t) = \sum_{i=1}^N B_i \sin(2\pi f_i t + \varphi_i) \quad (9)$$

其中 B_i 为信号的振幅, f_i 为频率。

多倍频简谐波叠加非倍频多简谐波信号:

$$y(t) = y_1(t) + y_2(t) \quad (10)$$

周期性冲击信号函数^[28]

$$y(t) = A_0 e^{-\omega \left(t - \frac{k}{f_d} \right)} \cos \left[2\pi f_n \left(t - \frac{k}{f_d} \right) \right] u \left(t - \frac{k}{f_d} - \frac{k_1}{f_d} \right) \quad (11)$$

其中, A_0 为振幅, ω 为阻尼系数, k 和 k_1 为系数, $u(t)$ 是单位阶跃函数, f_n 和 f_d 为信号单元的频率。

周期性调制信号函数^[28]:

$$y(t) = \sum_i^M (1 + A_i \cos(2\pi f_{ch} t + \psi_i) \cos [2\pi k f_m t + B_i \sin(2\pi f_{ch} t + \alpha_i) + \theta_i]) \quad (12)$$

其中 ψ_i , α_i 和 θ_i 为相位, f_m 和 f_{ch} 为信号单元的频率, M 为幅值调制和频率调制的最高阶次。

(5) 文本描述

通过对信号函数进行以谱参数特征为核心的数学特征提取,并按公式(4)转换为模块化的文本描述。

(6) 信号数据

通过对信号函数进行离散化采样,得到与之对应的信号数据,包含时域形式和频域形式。数据格式包括时间序列向量、图像矩阵或张量。

(7) 信号-文本问答对数据集

将信号数据作为已知信息,将信号数学特征的文本描述作为答案,采用问与答的形式将信号数据和文本描述进行匹配,制作为“信号数据-文本描述”

问答对数据集。

总体而言,MLM-Sig2Txt 是利用大规模“信号数据-数学特征-文本描述”问答对数据集,采用生成式预训练、指令微调等技术构建的支持信号、图像、文本等跨模态数据理解、生成和交互的人工智能模型。它的优势主要包括:①可同时支持时序向量、图像形式的信号数据作为模型输入。②可同时支持跨模态数据之间的双向理解和生成,通用性和扩展性强。③可对信号宏观定性特征进行强泛化文本表征。其劣势主要包括:①依赖大规模高质量训练和微调数据集,开发成本相对较高。②模型参数量巨大,推理成本相对较高。③对信号细节数学特征的精准提取及文本化表征所需的训练和推理成本较高。

由上可知,本文提出的 PAK-Sig2Txt 和 MLM-Sig2Txt 在训练成本、推理成本、文本化表征性能等方面各有优劣,特别是在监测信号特征的精细量化表征和宏观定性表征方面可以形成交叉互补。下文中构建的多模态智能体架构将嵌入上述 2 种 Sig2Txt 模型。

2 设备运维专业文本大模型(EOM-LLM)

2.1 专业文本数据集

为确保设备运维文本大模型的训练数据覆盖广泛且专业,从多个来源收集了高质量的文本数据。这些来源包括学术论文、教材、国际标准、ISO 18436 振动分析师教材、运维手册和运维企业工程技术资料等。采用系统化方法,从收集的文本资料中筛选并提取振动分析、故障诊断及设备运维相关内容。随后,对这些提取内容进行编排重组,形成了一个“格式统一”、“结构一致”的语料库,该语料库以问答对话的形式呈现,包括问题(X_q)和回答(X_a)。这些对话包含了针对设备运维相关专业知识与解答,以及用于设备运维的综合分析流程以及详细的维修步骤的问题与解答。为了解决设备运维专业语料库大规模自动生成的问题,本文提出了以下技术方案:

(1) 数据收集

为确保 EOM-LLM 的训练数据覆盖广泛且专业,从多个来源收集高质量的文本数据。这些来源包括学术论文、教材、国际标准、ISO 18436 振动分析师教材和设备运维企业工程技术资料等;

(2) 文本抽取

利用 PyMuPDF^[29],从搜集的 PDF 文档中提取

文本内容。若文本层缺失,则调用 Tesseract OCR + PyMuPDF 进行二次抽取,确保公式与表格信息不丢失;

(3) 人工初筛

由故障诊断、设备运维专业人员对原始文本进行主题标注与价值评估,从中筛选并提取振动分析、故障诊断及设备运维相关内容,删除无关或过时内容;

(4) 文本结构化

利用自然语言处理库 SpaCy^[30],对提取的文本进行语义单元分割,保留原文逻辑结构的同时按句子/段落切分文本,并执行词性标注及依存关系分析;

(5) 问答对生成

调用 Bonito^[31]执行条件任务生成,将结构化文本作为 Context,指定任务属性,生成格式为 (Instruction, Response) 的问答对,实现原始文本数据到问答对语料的自动转换;

(6) 数据校验

由振动专业人员执行双盲标注,采用 Kappa 系数评估问答对与原文一致性,并根据人工校验结果微调 Bonito 提示模板,实现迭代优化;

(7) 语料数据集输出

将校验后的问答对构建为设备运维语料数据

集,涵盖振动原理、数据采集、信号处理、状态监测、故障分析、维修措施、设备检测与诊断和设备知识 8 大类。

经过上述流程,本文构建了一个内容广泛、专业性强的设备运维专业文本数据集,为模型训练和优化提供了坚实基础。

2.2 模型架构

本文所构建的 EOM-LLM 的总体设计理念立足于对通用基础模型的细致微调。此过程涉及利用所构建的专业领域数据集,旨在增强通用基础模型在设备运维问题解答方面的效能。设计目标是经过微调的文本大模型在性能上达到甚至超越 ISO 18436 三级振动分析师^[32]人类专家级水准,进而为运维工程师提供高效且精确的智能运维支持。

图 4 展示了 EOM-LLM 的构建和 workflows,涵盖了从接收用户输入至输出解答的各个阶段。初始步骤中,用户通过客户端以文本形式提交关于机械设备运维过程中的问题。提交的文本信息随后依次经过预处理、分词、词嵌入等处理环节,以确保文本内容能被模型有效解析。借助 Q-Former 编码机制^[33],文本信息被转换成富含语义及上下文信息的高维数据表示,进而形成模型可处理的数据输入格式。




图 4 EOM-LLM 流程图

为开发该模型,本文已构建规模达 5k+问答对的高质量文本数据,用于监督式微调流程。模型开发依托于 LLaMA-Factory 开源框架^[34]。基础语言模型采用仅解码器架构,并通过自回归语言建模技术实现。以 GLM4^[35]为例,该模型针对多样化的应用场景,提供了多个参数规模的版本。GLM4 9B 版本

的主要配置如下:模型参数规模为 9B,由 36 个层级组成,每个层级具有 4 096 的隐藏层维度,注意力头数量设定为 32,最大上下文长度可达 128 000 令牌(token)。对于长度为 L 的文本序列,生成目标回答 $\mathbf{X}_a$ 的概率计算公式为:

$$p(\mathbf{X}_a | \mathbf{X}_q) = \prod_{i=1}^L p_{\theta}(x_i | \mathbf{X}_q, \mathbf{X}_{a,<i}) \quad (13)$$

其中 θ 是可训练参数, $\mathbf{X}_{a < i}$ 表示当前预测令牌 x_i 之前所有轮次的回答令牌, $\mathbf{X}_q$ 表示输入的问题文本。本文的硬件配置如表 1 所示, 软件框架采用了 Pytorch 2.1。

表 1 实验硬件配置

名称	配置
操作系统	Ubuntu
Intel CPU	Intel Xeon Platinum 8352V 36-core Processor
Memory	256GB
Framework	Pytorch 2.1
GPUs	8×Nvidia Geforce RTX4090

2.3 训练过程

为了使 GLM4 基础模型更好地适应设备运维领域的特定需求, 在完成高质量、高一致性数据集的构建后, 本文采用低秩自适应(LoRA)方法^[36]对模型进行微调。该技术通过引入低秩矩阵来降低参数更新的维度, 旨在减少计算成本与存储需求的同时, 维持或提升模型的性能表现。具体来说, 对预训练权重矩阵 $\mathbf{W}_0 \in \mathbf{R}^{m \times n}$ 进行低秩分解:

$$\mathbf{W} = \mathbf{W}_0 + \Delta \mathbf{W} \quad (14)$$

其中 $\Delta \mathbf{W} = \mathbf{B}\mathbf{A}$, $\mathbf{B}$ 和 $\mathbf{A}$ 是两个训练的参数矩阵, $\mathbf{B}$ 的维度为 $m \times r$, $\mathbf{A}$ 的维度为 $r \times n$, $r \ll \min(m, n)$ 是矩阵的秩, $\mathbf{W}$ 是新的权重矩阵。因此不需要再训练所有参数, 只对 $\mathbf{A}$ 和 $\mathbf{B}$ 中的权重进行梯度更新。 $\mathbf{W}_0$ 和注入矩阵 $\Delta \mathbf{W}$ 都与输入 $\mathbf{X}$ 相乘, 并进行坐标合并, 以获得适应新任务的特征表示。因此, 这个新的前向传播过程为:

$$\mathbf{F} = \mathbf{W}\mathbf{X} = \mathbf{W}_0\mathbf{X} + \Delta \mathbf{W}\mathbf{X} = \mathbf{W}_0\mathbf{X} + \mathbf{B}\mathbf{A}\mathbf{X} \quad (15)$$

其中, $\mathbf{F}$ 是输出特征, $\mathbf{X}$ 是输入特征, $\mathbf{W}_0\mathbf{X}$ 是没有 LoRA 的原始输出。 $\mathbf{A}$ 使用随机高斯初始化, $\mathbf{B}$ 使用零矩阵初始化, 以确保在开始阶段 $\Delta \mathbf{W} = 0$ 。此外, 在实践中, $\Delta \mathbf{W}\mathbf{X}$ 通过 α/r 缩放以稳定注入参数的学习, 其中 α 为缩放超参数。

表 2 训练参数设置

参数	指令微调参数
Cutoff_len	1 024
Learning_rate	5.0×10^{-5}
LoRA_alpha	16
LoRA_dropout	0
LoRA_rank	16
Num_train_epochs	20

表 2 展示了模型训练的参数设置, 该设置确保了训练过程的稳定性和效率。在训练过程中, 定期监测并记录训练损失值, 依据损失值的变化动态调

整学习率, 并采用 cosine(余弦退火)学习率调度策略^[37], 确保模型在各个训练阶段均能展现出优化的性能。

3 思维链范式多模态智能体

3.1 思维链范式

本文在多模态智能体架构中引入了设备诊断与运维思维链推理机制, 使模型在逐步推理中更好地捕捉和理解设备健康状态的特异性量化特征, 从而提升设备故障诊断和运维决策的准确性和可解释性。

目前, 基于深度学习的故障诊断模型在数据集方面, 大多依赖于监测信号与故障模式的黑箱式直接映射。在诊断逻辑方面, 一大类^[38]是将原始监测信号经过预处理后, 利用特征提取技术提取一系列统计指标。然后将统计指标作为模型的输入进行训练、微调、测试和部署。另一大类^[39]是将原始监测信号经过预处理后, 直接将信号时间序列作为模型的输入进行训练、微调、测试和部署。

上述第一类范式的优势是利用峭度、均方根、熵等几十种高度凝练的时域和频域统计指标, 实现信号数据的显著降维和信息表征。正如 1.1 节中所述, 其不足之处是这些指标不具备与故障模式的特异性关系, 特别是无法与特定的故障零部件相匹配, 比如同一台设备中不同型号的滚动轴承的故障诊断, 必须依据各自的特征频率才可完成诊断。

上述第二类范式的优势是保留了原始信号的完整信息作为模型的输入, 在具备大规模高质量带标签数据集的条件下可以训练出能定位到具体零部件的故障诊断模型。然而, 这一条件在机械设备运维领域始终无法达到。

总体而言, 传统范式存在 2 大核心问题:

(1) 数据驱动智能模型必备的大规模数据集

数据驱动智能运维模型公认的瓶颈是数据来源^[40], 与日常人类活动中含量丰富的图像、文本和视频数据集不同, 设备运维数据集在数量和质量上都受到了严重限制。长期以来, 传统范式的数据集构建理念是监测信号(数据)与故障模式(标签)的黑箱式直接映射。这种理念在图像识别、语音识别等通识领域大获成功, 是因为可以低成本、高质量地构建出大规模数据集。而在设备运维领域, 受限于故障数据量、数据标注难度和信号叠加问题等难题, 始终无法构建可满足数据驱动人工智能模型的大数据集^[40-41]。

(2) 监测数据到运维决策全流程强泛化可解释故障诊断是设备运维体系中的核心, 从 20 世纪

60 年代起发展至今^[42], 不管是从方法论、知识体系还是到技术手段, 都已经堪称成熟。换言之, 基于人类专家的故障诊断技术体系已可解决绝大部分机械装备运维应用场景, 而且可实现全流程可解释。但是依赖人类专家的诊断和运维模式存在覆盖面小、时效性差、培养周期长和知识体系分散等问题。而依赖传统范式的智能诊断模型在准确性、可靠性和泛化性等关键性能指标方面都还未能很好满足工程实际要求。

为解决上述核心问题, 本文提出了一种新范式——思维链文本基多模态智能体。思维链^[43]是一种用于增强人工智能模型推理能力的技术, 通过模拟人类专家的逐步推理和分析过程, 使得模型在复杂任务中能够进行多步思考和推理, 从而分析出设备的运行状态并识别潜在故障, 进而给出合理的维护建议。具体而言, 本文提出的思维链范式包含“数据集—模型—智能体”三个层面的技术内核和创新。

(1) 思维链式数据集构建体系:

本文所提出的新范式以监测信号的“数学特征”作为桥梁, 以人类专家开展设备运维的推理思维为指引, 形成了“监测信号-(数学特征+物理信息)-文本描述-故障模式”思维链式数据集架构。其中, “监测信号-数学特征-文本描述”大规模数据集通过第 1 节中提出的“信号-文本数据集生成器”批量化自动构建, “(数学特征+物理信息)-文本描述-故障模式”大规模数据集则可通过第 2 节中提出的设备运维专业语料生成技术批量化构建。这两部分数据集前后衔接即可实现“监测信号-(数学特征+物理信息)-文本描述-故障模式”思维链式数据集的低成本、大规模、高质量构建, 解决传统的“监测信号-故障模式”直接匹配的黑箱式数据集构建难题。

(2) 思维链式信号转文本模型:

以设备运维思维链为指引, 充分利用“时序信号-数学特征”之间映射关系的精准性和通识性, 提出了监测信号→数学特征→文本描述跨模态转换架构。该架构一方面可以充分利用通用大语言模型和多模态大模型基于大数据、大算力和大参数实现的通识领域强推理、强泛化能力, 另一方面可以利用本文第 1 节中提出的“信号-文本数据对生成器”低成本、高精度地构建“时序信号-数学特征-文本描述”数据集。这为站在通用大模型这一“巨人肩膀上”开展设备运维专业领域模型研发搭建了专业化“桥梁”。

(3) 多模态智能体:

本文以 EOM-LLM 为基座的多模态设备运维智能体, 吸纳了人类专家在信号处理、先验知识

和逻辑推理方面的深厚积累, 将监测信号(数值模态)、设备物理参数(结构化文本)、运维知识资料(非结构化文本)等跨模态数据融合解析为自然语言为核心的文本信息。得益于大规模文本数据集预训练+微调的 EOM-LLM 基座在自然语言理解、逻辑推理方面兼具通识性、专业性和灵活性, 多模态思维链智能体相比于传统单模态数据驱动的深度学习模型具有热启动、强泛化的特性。也就是在面对新的设备和场景时, 不再依赖新场景大规模数据的重新训练。而且利用“文本基”的包罗万象和易解释性, 可实现从监测数据到运维决策的全流程可解释。

图 5 所示为传统范式和本文新范式的思维过程对比。新范式主要包含以下几个步骤:

(1) 监测信号→数学特征: 从监测信号中提取一系列数学特征, 包括周期、幅值、相位、基频、谐波、载波频率、边频带等谱参数特征, 以及统计指标和非线性指标等宏观特征。

(2) 数学特征→文本描述: 将上述数学特征输出为结构化或非结构化的文本信息, 包含自然语言、表格和数值等等。

(3) 物理信息→文本描述: 将设备的结构、材料、工艺、工况等物理信息转换为文本描述。

(4) 文本描述+机理知识→故障模式: 将(2)、(3)的文本描述作为输入数据, 由 EOM-LLM 执行推理, 以文本形式输出设备健康状态、故障模式和维护决策等。

3.2 多模态智能体架构

图 6 所示为本文提出的思维链范式设备运维多模态智能体构建流程。该智能体的构建包含 3 大模块: 专业文本数据集、EOM-LLM 和 Sig2Txt。其中, 专业文本数据集的作用是为通用大语言模型提供设备运维专业知识补充, 显著增强其对于设备运维领域文本知识的理解和推理能力, 形成 EOM-LLM。进一步地, 基于第 1 节中所提出的 Sig2Txt 模型, 将监测信号的核心数学特征准确、量化的转换为文本数据, 并联合设备结构信息、工况信息和环境信息等其他文本数据, 作为 EOM-LLM 的输入。凭借通用 LLM 具有的超长上下文处理能力(比如典型的 128k tokens, 约 6.4 万~12.8 万字符的非结构化文本, 或 4 万~8 万字符的结构化文本), 再结合 EOM-LLM 对于故障机理和诊断知识的专业能力和强泛化能力, 可以在冗长的结构化或非结构化文本描述中, 提取出指向特定故障模式所需的特异性数学特征。最后经过模型推理最终输出设备健康状态、故障模式、故障程度和维护建议等运维决策信息。




图5 数据驱动的智能诊断模型传统范式与新范式对比




图6 智能运维多模态智能体构建流程

为实现上述目标，基于大模型智能体技术^[44-45]将前面小节中构建的 PAK-Sig2Txt、MLM-Sig2Txt 和 EOM-LLM 有机融合为多模态智能体，其架构如图 7 所示。该智能体以 EOM-LLM 为自治主体，围绕“记忆-规划-执行”三环节闭环运行：




图7 思维链范式智能运维文本基多模态智能体架构

- (1) 记忆层将短期窗口与向量化长期记忆解耦，既支持实时上下文检索，又保留案例沉淀；
- (2) 规划层采用 Planning → Making → CoT → Decomposition 四级递进策略，先在自然语言中生成

多步思维链,再细化为可调用工具指令;

(3) 执行层通过工具(tools)调用四类能力——算法库(Algorithms)、PAK-Sig2Txt、MLM-Sig2Txt 与图形表征库(PlotT-F)。各工具均以函数式接口暴露给智能体核心,实现多模态数据融合处理与分析流程。

与传统“多智能体松耦合集群”不同,本文将领域专家模型下沉为工具层,由 EOM-LLM 统一调度;这样既降低并发通信开销,也保持了大模型对全局上下文的一致性。该智能体设计兼顾了专业化(领域工具)与通用推理(LLM),避开了传统智能诊断系统架构所依赖的监测信号-故障模式“黑箱式”数据集体系,赋予了大模型设备运维专业化思维链模式:监测信号-信号数学特征+设备物理信息-先验知识-故障模式-维护决策,为设备运维多模态智能体提供了可行性强且资源友好的实现路径。

4 验证与评估

4.1 Sig2Txt 模型评估

(1) 实例 1: 单谐波信号

为了评估 Sig2Txt 模型的性能,本文首先采用单谐波信号进行验证。该信号的特征参数:频率为 50 Hz,幅值为 5 V,周期为 20 ms,初始相位设定为 0 rad。采用 1.3 节中基于先验算法知识的 Sig2Txt 模型输出的文本描述如下。

实例 1 信号的文本描述:

该信号是一个单简谐波周期信号。该信号的时域波形图中,信号周期是 0.02 s,幅值是 5 V。该信号的频谱图中,频率是 50 Hz,幅值是 5 V,相位是 0 rad。该信号的时域波形是一个简谐波,对应在频谱图中,有一根频率为 50 Hz 的谱线。

(2) 实例 2: 多倍频谐波与循环平稳复合信号

图 8 所示为采用 1.4 节中的信号-文本数据集生成器生成的另一个实例信号。该信号为多倍频谐波信号与循环平稳信号线性叠加而成。多倍频谐波信号由 4 个谐波信号组成,谐波的基频为 11 Hz。循环平稳信号的循环频率为 43 Hz。从图 8 可以看出,该复合信号的图谱成分非常复杂,难以直接将谱参数等核心数学特征准确转换为文本描述。






图 8 实例 2 信号原始图谱

采用本文基于先验算法知识的 Sig2Txt 模型对该实例信号进行处理。其中,自适应信号分解模块处理后的结果如图 9 所示。从图 9 可看到复合信号被自适应分解为 2 个分量信号。Sig2Txt 模型最终输出的文本描述如下。





(f) 第二组重构信号的包络谱

图 9 实例 2 信号经信号分解模块处理后的结果

实例 2 信号的文本描述：

该信号是一个组合信号，即由多倍频谐波信号和循环平稳信号叠加得到的信号。该信号的时域图中，波形较为复杂，没有固定周期。该信号的频谱图中，多倍频谐波信号基频的频率是 10.98 Hz，幅值是 0.23 m/s^2 ，相位是 0.78 rad ；2 倍频的频率是 22.01 Hz，幅值是 0.146 m/s^2 ，相位是 3.02 rad ；3 倍频的频率是 32.99 Hz，幅值是 0.037 m/s^2 ，相位是 -1.36 rad ；4 倍频的频率是 43.98 Hz，幅值是 0.21 m/s^2 ，相位是 -1.2 rad 。循环平稳信号包络谱中的基频频率是 42.99 Hz，幅值是 0.215 m/s^2 ；2 倍频的频率是 85.98 Hz，幅值是 0.089 m/s^2 ；3 倍频的频率是 128.975 Hz，幅值是 0.041 m/s^2 ；4 倍频的频率是 172.00 Hz，幅值是 0.0096 m/s^2 ；5 倍频的频率是 214.99 Hz，幅值是 0.0081 m/s^2 。该信号叠加了 1 个多倍频谐波信号和 1 个循环平稳信号成分，所以可以在幅值谱中看到 10.98 Hz 的谐波，在包络谱中看到 42.99 Hz 的谐波。

通过以上两个实例的文本描述结果可知，Sig2Txt 模型可以准确提取监测信号的数学特征，特别是谱参数特征，并进一步将数学特征精确转换为模块化的文本描述。这为思维链范式设备运维智能体提供了坚实的数据基础。

4.2 EOM-LLM 评估

为了评估所构建的 EOM-LLM 性能，与业界公认同期先进大模型进行了详细对比验证。这里选用 ChatGLM4 9B 作为本文模型的基座 LLM，对比模型包括 GPT 4o、ChatGLM 4 和 Qwen 2.5。各模型参数规模和基准能力对比如表 3 所示。为了标准化、专业化的测试，本文以国际标准化组织制定的设备运维专业工程师培训与认证的 ISO 18436 为依据开展测试。该标准将专业工程师分为 1~4 级，其中，三级和四级为专家级。每个级别的认证考试中，分数达到 70 分以上则通过认证。本文选取 ISO 18436 三级振动分析师认证考试中的 70 道纯文本题目输入到文本大模型中进行测试。这些测试题目

涵盖了设备运维领域中的八类知识点：状态监测、振动原理、数据采集、信号处理、故障分析、纠正措施、设备检测与诊断和设备知识。

表 3 各模型参数量和基准能力对比^[46-48]

模型	参数体量/B	MMLU 得分(%)
ChatGLM4	9	75
Qwen 2.5	72	86
GPT 4o	>200	87

各模型的测试结果如图 10 所示。从中可以看出，本文构建的 EOM-LLM 在综合测试中取得了高于 70% 的准确率，依据 ISO 18436 标准，达到了人类三级振动分析师的水平。在所考察的八类知识点上，本文模型的准确率均高于业界的主流大模型，同时展现出全面且稳定的性能。该模型在八个知识点上表现均衡，没有出现某一知识点特别突出而其他知识点相对薄弱的情况。相比之下，GPT 4o、ChatGLM 4 以及 Qwen 2.5 的准确率都低于本文模型。具体来说，GLM 4 在故障分析方面的准确率是最低的，GPT4o 在设备知识方面的准确率是最低的，而 Qwen 2.5 的整体表现略优于其他两个模型。




图 10 本文模型与其他三种大模型的测试对比结果

以上分析和对比结果表明，本文模型在参数量 (9B) 显著小于对比模型 (>200B) 的情况下取得了更高的准确性，也就是可以在相对较少计算资源条件下取得更高的计算效率和效果。

4.3 多模态智能体评测

为综合评估思维链范式多模态智能体在设备运维专业领域的性能，本小节开展了多项评测。首先选取 ISO 18436 振动分析师认证考试中的 11 道图文题进行评测分析。图文题内容如图 11 所示。这里以

图文题 1 为例进行详细讨论。图文题 1 给出的已知条件中包含设备监测信号的时域波形图和幅值谱图, 以及设备的转速。其中, 前者是信号的数学特征信息, 后者是设备的物理特征信息。














图 11 振动分析师图文题

表 4 和图 12 为本文模型、ChatGLM 4 和 GPT 4o 的多模态分析处理结果。该题的正确答案是: “A: 不平衡”。

表 4 图文题 1 的测试结果对比

模型名称	回答结果
正确答案	A. 不平衡
ChatGLM 4	D. 共振
GPT4o	B. 不对中
本文模型	A. 不平衡

ChatGLM 4 的输出答案为：“D. 共振”。如图 12 所示，该模型将题述信号的特征解读成了是共振现象导致的。




图 12 本文模型与其它两种模型的输出结果

GPT-4o 的输出答案为：“B：不对中”。GPT-4o 主要基于频谱特征的分析，识别到信号中的频率成分并做出判断。然而，GPT-4o 在分析信号时未量化考虑 2 倍频及高倍频的幅值，导致诊断结果不准确。

相比之下，本文的思维链范式智能体依托于 Sig2Txt 模块获取了全面、准确的数学特征描述，再结合设备物理信息，经过 EOM-LLM 的推理分析，最终准确地诊断出该设备处于不平衡状态，做出了正确的回答：“A：不平衡”。

11 道图文题的准确率统计结果如表 5 所示，本文模型的准确率达到 81.81%，明显高于对比模型

表 5 振动分析师图文题测试结果对比

模型	准确率(%)
本文模型	81.81
ChatGLM-4	36.36
GPT-4o	54.54

ChatGLM-4 和 GPT-4o。

接着，为验证多模态智能体在实际工程场景中的性能，本文构建了设备运维真实数据集用于对比评测。真实数据集包含机械工业仪器仪表综合技术经济研究所提供的 90 条实际工程闭环案例数据，以及来源于公开数据集的 92 条试验台数据。其中，公开数据集包括凯斯西储大学轴承数据^[49]、武汉大学转子故障数据^[50]和 MAFAULDA 机械故障数据集^[51]。上述实际工程数据和公开数据集涵盖了不对中、不平衡和滚动轴承三大类故障。为了提升评测维度，这里将本文智能体的基座 LLM 模型更新为 QWQ 32B^[52]，对比模型则采用与之发布日期相近的多模态大模型 GPT o1 和 GPT o3pro，它们的参数量和基准能力对比如表 6 所示。从表 6 可看出，QWQ 32B 参数量最小，而且基准能力最低。本文模型与对比模型在零样本、热启动条件下的真实数据集评测结果的准确率及推理速度统计如表 7 所示。从表 7 可以看出，本文模型的准确率达到 80.2%，而对比模型 GPT o1 和 GPT o3pro 的准确率分别为 36.8% 和 40.7%，显著低于本文模型。而且，本文模型的平均推理速度是 36.2 秒，也明显优于对比模型 GPT o1 和 GPT o3pro 的 47.9 秒和 184.3 秒。

表 6 各模型参数量和基准能力对比^[53-54]

模型	参数量/B	MMLU 得分(%)
QWQ 32B	32	76.4
GPT o1	>300	91.8
GPT o3pro	>500	>92

以上验证对比结果表明，相比于在通识基准数据集上的优异表现，通用多模态大模型在设备运维专业领域真实数据集中的性能明显不足。而本文模型则以最小的参数规模，在设备运维专业领域中表现出色，特别是在零样本、热启动条件下的多模态数据解读和处理方面明显优于现有主流多模态大模型。

表 7 真实数据集零样本热启动测试结果对比

模型	工程数据 案例数量	公开数据 集案例数	总案 例数	正确诊 断数量	平均推 理速度/s	准确率 (%)
本文模型				146	36.2	80.2
GPT o1	90	92	182	67	47.9	36.8
GPT o3pro				74	184.3	40.7

5 结论

本文提出的思维链范式智能运维多模态智能体,以人类专家思维链推理机制为指引,依托所构建的 Sig2Txt 模型和设备运维专业文本大模型,可实现对机械设备的热启动可解释智能运维。以 ISO 标准化测评结果表明,该智能体相比现有的主流大模型具有明显的优势。具体而言,本文的多模态专业化智能体在设备状态监测、故障诊断、维护建议等八大类核心任务上表现优异,准确率和专业性均达到人类三级振动分析师水平。而且,在处理设备运维多模态数据时,该模型也展现了显著优势。本文的主要创新如下:

(1) 以监测信号的“数学特征”作为桥梁,以人类专家推理过程为指引,形成了监测信号-(数学特征+物理信息)-文本描述-故障模式的思维链式数据集架构。基于所提出的信号-文本数据集生成器和设备运维专业文本数据集,可实现思维链式数据集的低成本、大规模、高质量构建,解决传统的“监测信号-故障模式”直接匹配的黑箱式数据集构建难题,可望突破数据驱动智能运维模型的基础设施瓶颈。

(2) 提出的思维链式信号转文本模型,以设备运维思维链为指引,充分利用“时序信号-数学特征”之间映射关系的精准性和通识性,构建了监测信号→数学特征→文本描述跨模态转换架构。这为站在通用大模型这一“巨人肩膀上”开展设备运维专业领域模型研发搭建了专业化“桥梁”。

(3) 以 EOM-LLM 为基座的多模态智能运维智能体将监测信号、设备物理参数、运维知识资料等跨模态数据融合解析为自然语言为核心的文本信息。得益于大规模文本数据集预训练+微调的 EOM-LLM 基座在自然语言理解、逻辑推理方面兼具的通识性、专业性和灵活性,多模态智能运维智能体相比于传统单模态数据驱动的深度学习模型具有热启动、强泛化的优势。

以设备运维专业工程师培训与认证的国际标准 ISO 18436 为依据开展的标准化和专业化测试,以及真实数据集评测结果表明,本文模型在设备运维专业领域的纯文本分析和多模态数据融合方面都明显优于现有的主流大模型。

基于上述研究,本文提出的思维链范式多模态智能体为机械设备智能运维提供了一种具有强泛化和高可行性的解决方案,兼具技术创新与工程应用价值。在后续的研究中,专业文本数据集需要持续

扩充,以进一步提高模型的专业能力和泛化能力。特别是提炼自工程实际案例的信号分析、故障诊断、运维决策及维护反馈信息等完整思维链文本数据,从而提升专业文本大模型对于工程实际案例的适应性。此外, Sig2Txt 模型也需要不断优化,提高其对多模态信号数据核心数学特征的精确化文本表征性能。还需加强“信号-文本数据集生成器”对于实际工程中的噪声和非线性特征的信号生成精度及文本描述性能,并且在数据集中持续补充高质量的实际工程信号-文本描述数据对。

参考文献

- [1] 臧冀原,刘宇飞,王柏村,等.面向 2035 的智能制造技术预见和路线图研究[J].机械工程学报,2022,58(4): 285-308.
ZANG Jiyuan, LIU Yufei, WANG Baicun, et al. Technology forecasting and roadmapping of intelligent manufacturing by 2035[J]. Journal of Mechanical Engineering, 2022, 58(4): 285-308.
- [2] 汪俊亮,高鹏捷,张洁,等.制造大数据分析综述:内涵、方法、应用和趋势[J].机械工程学报,2023,59(12): 1-16.
WANG Junliang, GAO Pengjie, ZHANG Jie, et al. A review of manufacturing big data: connotation, methodology, application and trends[J]. Journal of Mechanical Engineering, 2023, 59(12): 1-16.
- [3] TAUHEED M, ANURAG C, SHAHAB F. Multi-sensor fault diagnosis for misalignment and unbalance detection using machine learning[J]. IEEE Transactions on Industry Applications, 2023, 59(5): 5749-59.
- [4] LEI Yaguo, YANG Bin, JIANG Xinwei, et al. Applications of machine learning to machine fault diagnosis: A review and roadmap[J]. Mechanical Systems and Signal Processing, 2020, 138: 106587.
- [5] CHEN Jiaxian, HUANG Ruyi, CHEN Zhuyun, et al. Transfer learning algorithms for bearing remaining useful life prediction: A comprehensive review from an industrial application perspective[J]. Mechanical Systems and Signal Processing, 2023, 193: 110239.
- [6] 黄包裕,张永祥.一种基于三步法的轴承故障诊断方法[J].振动工程学报,2024(14): 51-68.
HUANG Baoyu, ZHANG Yongxiang. Rolling element bearing fault diagnosis using a three-step scheme[J]. Journal of Mechanical Engineering, 2024(14): 51-68.
- [7] 任杉,王晋,赵欣,等.复杂产品智能设计与主动运维“双馈式”制造服务方法体系[J].机械工程学报,2024, 60(06): 127-36.

- REN Shan, WANG Jin, ZHAO Xin, et al. "Doubly-fed" manufacturing service of intelligent design and preventive maintenance for complex products [J]. *Journal of Mechanical Engineering*, 2024, 60(06): 127-36.
- [8] ZHENG Zhe, WANG Fei, GONG Guofang, et al. Intelligent technologies for construction machinery using data-driven methods [J]. *Automation in Construction*, 2023, 147: 104711.
- [9] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database[C]. 2009 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2009: 248-255.
- [10] FANG A, KORNBLITH S, SCHMIDT L. Does progress on ImageNet transfer to real-world datasets [J]. *Advances in Neural Information Processing Systems*, 2024, 36: 25050-25080.
- [11] BROWN T B. Language models are few-shot learners[J]. *Arxiv, Preprint Arxiv*: 2005.14165, 2020.
- [12] WU T, HE S, LIU J, et al. A brief overview of ChatGPT: The history, status quo and potential future development[J]. *IEEE/CAA Journal of Automatica Sinica*, 2023, 10(5): 1122-1136.
- [13] SILVER D, SCHRITTWIESER J, SIMONYAN K, et al. Mastering the game of go without human knowledge[J]. *Nature*, 2017, 550(7676): 354-359.
- [14] MIAO Q, ZHENG W, LV Y, et al. DAO to HANOI via DeSci: AI paradigm shifts from AlphaGo to ChatGPT[J]. *IEEE/CAA Journal of Automatica Sinica*, 2023, 10(04): 877-897.
- [15] CHIB P, SINGH P. Recent advancements in end-to-end autonomous driving using deep learning: A survey[J]. *IEEE Transactions on Intelligent Vehicles*, 2023.
- [16] HAYDARI A, YILMAZ Y. Deep reinforcement learning for intelligent transportation systems: A survey[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2020, 23(1): 11-32.
- [17] FEDUS W, ZOPH B, and SHAZEER N. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity [J]. *Journal of Machine Learning Research*, 2022, 23(120): 1-40.
- [18] RADFORD A, WU J, CHILD R, et al., Language models are unsupervised multitask learners [R/OL]. San Francisco: OpenAI, 2019-02. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [19] BROWN T. Language models are few-shot learners[J]. *Arxiv, Preprint Arxiv*: 2005.14165, 2020.
- [20] OpenAI. GPT-4 Technical Report [EB/OL]. San Francisco: OpenAI, 2023-03-27 [2025-08-04]. <https://cdn.openai.com/papers/gpt-4.pdf>.
- [21] ZENG A, LIU X, DU Z, et al. Glm-130b: An open bilingual pre-trained model[J]. *Arxiv, Preprint Arxiv*: 2210.02414, 2022.
- [22] WEI J, TAY Y, BOMMASANI R, et al. Emergent abilities of large language models[J]. *Arxiv, Preprint Arxiv*, 2206.07682, 2022.
- [23] BUBECK S, CHANDRASEKARAN V, ELDAN R, et al. Sparks of artificial general intelligence: Early experiments with gpt-4[J]. *Arxiv, Preprint Arxiv*: 2303.12712, 2023.
- [24] VASWANI A, SHAZEER N, et al. Attention is all you need [J]. *Arxiv, Preprint Arxiv*: 1706.03762, 2023.
- [25] HUANG Jinfeng, ZHANG Feibin, SAFAEI B, et al. The flexible tensor singular value decomposition and its applications in multisensor signal fusion processing[J]. *Mechanical Systems and Signal Processing*, 2024, 220: 111662.
- [26] HUANG Jinfeng, ZHANG Feibin, Coombs T, et al. The first-kind flexible tensor SVD: innovations in multi-sensor data fusion processing[J]. *Nonlinear Dynamics*, 2025, 113: 6541-6559.
- [27] 张贤达. 现代信号处理[M]. 清华大学出版社有限公司, 2015.
- ZHANG Xianda. Modern signal processing[M]. Beijing: Press of Tsinghua University, 2015.
- [28] FENG Z, ZUO M. Vibration signal models for fault diagnosis of planetary gearboxes[J]. *Journal of Sound and Vibration*, 2012, 331(22): 4919-4939.
- [29] Jorj X. McKie. PyMuPDF: A high performance Python library for data extraction, analysis, conversion & manipulation of PDF (and other) documents[EB/OL]. 2023-05. <https://github.com/pymupdf/PyMuPDF>.
- [30] VASILIEV Y. Natural language processing with Python and spaCy: A practical introduction[M]. No Starch Press, 2020.
- [31] NAYAK N, NAN Y, TROST A, et al. Learning to generate instruction tuning datasets for zero-shot task adaptation[J]. *Arxiv, Preprint Arxiv*: 2402.18334, 2024.
- [32] International Organization for Standardization. ISO 18436-2: 2014 Condition monitoring and diagnostics of machines — Requirements for qualification and assessment of personnel — Part 2: Vibration condition monitoring and diagnostics [S]. Geneva: ISO, 2014.
- [33] LI Junan, LI Dongxu, SAVARESE S, et al. BLIP-2: bootstrapping language-image pretraining with frozen image encoders and large language models[C]//

- International Conference on Machine Learning, 2023, 19730-19742.
- [34] ZHE Yutong ZHANG Rui, ZHANG Jie, et al. Llamafactory: Unified efficient fine-tuning of 100+ language models[J]. Arxiv, Preprint Arxiv: 2403.13372, 2024.
- [35] GLM T, ZENG A, XU B, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools[J]. Arxiv, Preprint Arxiv: 2406.12793, 2024.
- [36] HU E, SHEN Y, WALLIS P, et al. Lora: Low-rank adaptation of large language models[J]. Arxiv, Preprint Arxiv: 2106.09685, 2021.
- [37] LOSHCHILOV I, HUTTER F. Sgdr: Stochastic gradient descent with warm restarts[J]. Arxiv, Preprint Arxiv: 1608.03983, 2016.
- [38] ZHAO Xiaoli. Intelligent fault diagnosis of gearbox under variable working conditions with adaptive intraclass and interclass convolutional neural network[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(9): 6339-6353.
- [39] XU Haifeng, WANG Xu, HUANG Jinfeng, et al. Semi-supervised multi-sensor information fusion tailored graph embedded low-rank tensor learning machine under extremely low labeled rate[J]. Information Fusion, 2024, 105: 102222.
- [40] YEUNG Y, PAUL-AJUWAPE A, TAHIRY F, et al. RoSA: A mechatronically synthesized dataset for rotodynamic system anomaly detection[J]. 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems, 2022.
- [41] HENG A, ZHANG Sheng, TAN A, et al. Rotating machinery prognostics: State of the art, challenges and opportunities[J]. Mechanical Systems and Signal Processing, 2009, 23: 724-739.
- [42] 王国彪, 何正嘉, 等. 机械故障诊断基础研究“何去何从”[J]. 机械工程学报, 2013, 49(1): 63-72.
- WANG Guobiao, HE Zhengjia, et al. Basic research on machinery fault diagnosis—what is the prescription[J]. Journal of Mechanical Engineering, 2013, 49(1): 63-72.
- [43] WEI Jason, WANG Xuezhi, SCHUURMANS Dale, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 24824-24837.
- [44] GUO T, CHEN X, WANG Y, et al. Large language model based multi-agents: A survey of progress and challenges[J]. Arxiv, Preprint Arxiv: 2402.01680, 2024.
- [45] WENG Lilian. Llm powered autonomous agents[EB/OL]. 2023-06. <https://lilianweng.github.io/posts/2023-06-23-agent/>.
- [46] OSNI O. Introducing GPT-4o: the fastest and most powerful AI yet[EB/OL]. 2024-05. https://www.swiftask.ai/blog/gpt-4o?utm_source=chatgpt.com
- [47] GLM T, ZENG A, XU B, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools[J]. Arxiv, Preprint Arxiv: 2406.12793, 2024.
- [48] QWEN Team. Qwen2.5-LLM: Extending the boundary of LLMs[EB/OL]. 2024-09. <https://qwenlm.github.io/blog/qwen2.5-llm/>.
- [49] SMITH W A, RANDALL R B. Rolling element bearing diagnostics using the Case Western Reserve University data: A benchmark study[J]. Mechanical Systems and Signal Processing, 2015, 64: 100-131.
- [50] LIU Dong, XIAO Zhihuai, HU Xiao, et al. Feature extraction of rotor fault based on EEMD and curve code[J]. Measurement, 2019, 135: 712-724.
- [51] MARINS M, RIBEIRO F, NETTO S, et al. Improved similarity-based modeling for the classification of rotating-machine failures[J]. Journal of the Franklin Institute, 2018, 355(4): 1913-1930.
- [52] TEAM Q. Qwq-32b: Embracing the power of reinforcement learning[EB/OL]. 2025-03. <https://qwenlm.github.io/blog/qwq-32b>.
- [53] Artificial analysis. QwQ-32B - intelligence, performance & price analysis[EB/OL]. 2025-03. https://artificialanalysis.ai/models/qwq-32b?utm_source=chatgpt.com.
- [54] OpenAI. O1 and new tools for developers[EB/OL]. 2024-12. https://openai.com/index/o1-and-new-tools-for-developers/?utm_source=chatgpt.com.

作者简介: 黄金凤, 女, 1991 年出生, 博士。主要研究方向为机械故障诊断及智能运维。

E-mail: hjinfeng1991@163.com

张飞斌(通信作者), 男, 1986 年出生, 博士, 助理研究员。主要研究方向为机械动力学、信号处理和智能运维。

E-mail: zfeibin@mail.tsinghua.edu.cn

褚福磊, 男, 1959 年出生, 博士, 教授, 博士研究生导师。主要研究方向为大型旋转机械的动力学分析和故障诊断。

E-mail: chufu@mail.tsinghua.edu.cn