

知识图谱增强的大语言模型辅助通信网络运维

胡记伟¹, 赵明明¹, 李旺^{1*}, 吕建新², 周方³, 欧阳才校⁴, 张鹏¹

(1. 武汉烽火技术服务有限公司, 武汉 430205; 2. 烽火通信科技股份有限公司, 武汉 430205;

3. 武汉铁路职业技术学院, 武汉 430205; 4. 武汉软件工程职业学院, 武汉 430205)

(* 通信作者电子邮箱 liwang8414@fiberhome.com)

摘要:随着通信网络的发展,通信网络的结构变得越来越复杂,网络设备的更新逐步加快,导致通信网络运维(O&M)工作变得越来越复杂,人工O&M面临着巨大的认知负担,且O&M人员需要掌握海量的O&M知识和具备丰富的O&M经验。为了解决这个问题,提出知识图谱(KG)增强的大语言模型(LLM)辅助通信网络O&M方法。首先,分析通信网络O&M领域的人员信息、设备信息和历史数据等构成的通信网络智能O&M本体结构,并应用O&M领域本体进行实体知识抽取,构建专业的KG;其次,应用LLM检索增强生成(RAG)技术,结合通信网络O&M数据的特征,构建面向通信网络智能O&M的RAG知识库;最后,提出一种基于KG增强的大语言模型O&M智能体(Agent)方法,应用KG增强LLM提示词在KG中查找关联信息,并将关联信息输入RAG知识库获取对应的历史解决方案。在LLM回答阶段,将所有内容作为提示词输入基础LLM中,从而提升LLM问答的准确性。此外,设计通信网络智能O&M系统进行网络O&M智能问答实验。实验结果表明,所提方法能准确完成通信网络O&M问题答案的生成,有效地减轻了O&M人员认知负担,并提升了O&M效率。

关键词:知识图谱;大语言模型;智能运维;通信网络;检索增强生成

中图分类号:TN914 **文献标志码:**A

Knowledge graph-enhanced LLM-assisted communication network operation and maintenance

HU Jiwei¹, ZHAO Mingming¹, LI Wang^{1*}, LYU Jianxin², ZHOU Fang³, OUYANG Caixiao⁴, ZHANG Peng¹

(1. Wuhan FiberHome Technical Services Company Limited, Wuhan Hubei 430205, China;

2. FiberHome Telecommunication Technologies Company Limited, Wuhan Hubei 430205, China;

3. Wuhan Railway Vocational College of Technology, Wuhan Hubei 430205, China;

4. Wuhan Vocational College of Software and Engineering, Wuhan Hubei 430205, China)

Abstract: As the structure of communication networks has become complex increasingly and the update of network equipments has become rapid increasingly, the communication network Operation and Maintenance (O&M) has become complex increasingly. As the result, manual O&M faces a huge cognitive burden, and O&M personnel need to master a vast amount of O&M knowledge and rich O&M experience. To address this challenge, a Knowledge Graph (KG)-enhanced LLM (Large Language Model)-assisted communication network O&M method was proposed. Firstly, the structure of the communication networks intelligent O&M domain ontologies were analyzed, encompassing personnel information, equipment information, and historical data, and the intelligent O&M domain ontologies were used to extract entity knowledge, which contributed to the construction of a specialized KG. Then, the LLM Retrieval-Augmented Generation (RAG) technology was applied, and the characteristics of communication network O&M data was combined, an RAG knowledge base was constructed for communication network intelligent O&M. Finally, an Agent method of O&M based on KG-enhanced LLMs was proposed to apply KG-enhanced LLM prompts to search the related information in the KG, and the related information was input into the RAG knowledge base to obtain corresponding historical solutions. During the response phase of the LLM, all content was input into the foundation LLM as prompts, thereby enhancing the accuracy of the LLM's answers. In addition, a communication network intelligent O&M system was designed to conduct network O&M intelligent question and answer experiments. Experimental results demonstrate that the proposed method generates answers to communication network O&M questions accurately, reducing the cognitive burden on O&M personnel effectively and enhancing O&M efficiency.

Key words: Knowledge Graph (KG); Large Language Model (LLM); intelligent Operation and Maintenance (O&M); communication network; Retrieval-Augmented Generation (RAG)

0 引言

通信网络已经成为影响国民经济、生活和安全的重要基础设施^[1],网络运维(Operation and Maintenance, O&M)是保障通信网络稳定运行的关键环节^[2]。随着通信技术的发展,通信网络的复杂性急剧增加。依靠人工运维的方式存在运维效率低、耗时费力,运维人员需要掌握海量的设备原理,还需要具有丰富的运维经验^[3]。缺乏经验的运维人员无法完成复杂的运维任务^[4],运维经验的积累也需要花费较长的时间。

随着人工智能技术的发展,大语言模型(Large Language Model, LLM)和知识图谱(Knowledge Graph, KG)在知识问答、智能辅助方面得到了广泛的应用^[5]。LLM具备强大的表征学习能力和泛化能力,能够处理海量的数据,从中提取有用信息,实现实时对话和智能问答。知识图谱能有效组织知识和经验,通过网络化的实体关系,提供智能决策和支持。在通信网络中,LLM和知识图谱技术也开始得到有效的应用^[6]。例如,在自智网络中应用LLM和知识图谱技术能够预测和定位网络故障,辅助智能决策。为了解决通用LLM在通信网络运维领域知识缺乏导致无法

收稿日期:2024-09-27;修回日期:2024-12-22;录用日期:2024-12-27。 基金项目:国家重点研发计划项目(2022YFB2901200)。

作者简介:胡记伟(1985—),男,河南周口人,高级工程师,硕士,主要研究方向:智能运维、服务型制造; 赵明明(1982—),男,河北邱县人,高级工程师,硕士,主要研究方向:信息通信网络智能运维、人工智能; 李旺(1990—),男,湖南益阳人,工程师,博士,主要研究方向:人工智能、信息通信网络智能运维; 吕建新(1966—),男,湖北武穴人,教授级高级工程师,主要研究方向:未来网络体系架构、算力网络; 周方(1982—),女,湖北荆州人,教授,硕士,主要研究方向:软件工程、分布式处理; 欧阳才校(1983—),男,湖北黄石人,高级工程师,硕士,主要研究方向:光纤通信、人工智能; 张鹏(1978—),男,河北邢台人,高级工程师,硕士,主要研究方向:AI大模型、信息通信技术。

准确回答的问题,研究人员采用 LLM 检索增强生成(Retrieval-Augmented Generation, RAG)技术,构建专业向量知识库,提升了通用 LLM 在通信网络运维专业问题回答的准确性。然而,直接构建专业向量知识库的 RAG 方法难以处理全局性问题。尤其针对通信网络故障问题,需要整合多个文本语料库的查询和相关逻辑关系,通用 RAG 方法难以适应^[6]。

针对当前通信网络运维面临的上述问题,本文首先研究面向通信网络运维的知识图谱构建方法,构建一个面向通信网络运维的知识图谱,将分散在不同来源、不同形式的运维知识进行整合和关联,形成一个统一的知识体系,帮助后续通信网络运维 RAG 检索找到全面的相关运维知识,提升检索的准确性;其次将 RAG 技术应用在通信网络智能运维中,通过知识图谱和 LLM 处理通信网络运维知识,实现了传统人工运维过程的高准确度的智能问答服务,辅助运维人员完成通信网络运维操作,减轻运维人员的认知负担,提升运维效率。

1 国内外研究现状

当前通信网络智能运维系统中逐步开始应用知识图谱(KG)、LLM 技术辅助运维操作。KG 是一种表示现实世界中实体及其关系的图结构模型,自 2012 年 Google 首次提出以来,受到了广泛的关注和研究^[7]。知识图谱被广泛应用于信息检索、问答系统、推荐系统等领域,极大地推动了人工智能的发展^[8]。早期的知识图谱主要应用于通用领域,如 DBpedia 和 YAGO,通过从网页等大型数据源中提取结构化信息,构建了丰富的知识库^[9]。

在通信网络智能运维领域,知识图谱通过构建结构化的语义网络,有效组织和利用网络知识、经验、规则等,为智能运维提供强大的数据支持。应用知识图谱技术,可以实现通信网络故障预测、故障定位、自动化处理等功能。Wei 等^[10]利用知识图谱技术构建了一个通信网络故障预测系统,通过分析历史故障数据,预测未来可能出现的故障类型和位置。Li 等^[11]将知识图谱引入告警分析流程,同时提出一种基于图神经网络的推理模型,通过对告警知识图谱进行关联推理,实现网络故障定位。Zheng 等^[12]提出一种基于图嵌入的知识图谱优化方法,通过训练图嵌入模型降低知识图谱的维度和复杂度,提高查询效率。早期的知识图谱依靠人工添加新的数据,在实际应用过程中,当新的网络设备或网络故障出现时,需要手动更新知识图谱才能解决新的网络问题。针对知识图谱扩展问题,Wu 等^[13]提出 TIE(Time-aware Incremental Embedding)框架,面向增量式的时间知识图谱补全任务,针对知识图谱随时间不断新增与删除事实的特点,设计了结合经验重放、时间正则化和删除事实负样本建模的增量学习机制,为动态环境下的知识图谱扩展提供了新的解决思路。

LLM 是人工智能领域的一个重要分支,在自然语言处理、计算机视觉、语音识别等领域,已经取得了显著的成果^[14]。在通信领域,LLM 技术也得到了有效的应用。Islam 等^[15]提出一种基于深度学习的 LLM 故障预测方法,通过提取网络运行数据的特征和训练模型,实现了对通信网络故障的准确预测。

Ma 等^[16]结合 LLM 和自然语言处理技术,实现了对网络设备日志的智能解析和分析。通过构建结构化的语义网络,LLM 可以有效组织和利用网络知识、经验、规则等,为运维人员提供智能的决策支持。Wang 等^[17]提出一种 LLM 赋能的光网络框架,通过在控制层部署由 LLM 驱动的智能体,实现对物理层的智能控制以及与应用层的高效交互。随着技术的不断发展,通信网络智能运维 LLM 的应用范围也在不断扩大。Alsaif 等^[18]提出了一种基于 LLM 和计算机视觉技术的网络设备视觉监控与故障识别方法,利用网络设备的图像数据进行智能分析,实现了对设备外观异常的自动检测和故障识别,提升了网络运维的智能化水平。尽管 LLM 技术在专业领域场景得到了广泛的应用,由于通用 LLM 训练时缺乏专业领域场景的数据,直接应用它进行通信网络智能运维辅助时效果较差,亟须一种能通过专业知识增强的 LLM 辅助通信网络运维方法。

2 本文方法

基于知识图谱增强的大语言模型辅助通信网络智能运维方法的框架如图 1 所示,主要包括 3 个核心部分:通信网络知识图谱构建、基于 LLM 的运维知识库构建和知识图谱增强 LLM 问答方法。首先,应用通信网络的运维数据构建通信网络知识图谱,用于描述网络结构、设备属性、故障模式等关键信息;其次,利用大语言模型 RAG 技术,加载通信网络中各类设备文档、手册和人工运维知识,并读取文档中的文本信息,在文本向量中匹配出与问句向量最相似的内容;最后,将匹配出的文本作为上下文和知识图谱检索内容一起添加到提示词中,提交给基础 LLM 生成回答,辅助人工运维操作。




图1 本文方法的框架

在知识图谱应用阶段,需要收集通信网络的相关数据,包括网络结构、设备信息、故障记录等。通过清洗、整合和关联这些数据,构建出包含实体、属性、关系等元素的通信网络知识图谱。然后通过知识检索查找通信网络智能运维相关知识,并将检索到的内容作为提示词输入 LLM 知识库中。在 LLM 的运维知识库应用阶段,主要应用各种格式的设备文档、手册和人工运维等文件,加载在构建的文件库中并读取文本,然后对文本进行分割和向量化。在应用过程中,先接收知识图谱检索的内容,再根据知识图谱内容在文本向量中匹配出最相似的文本内容,并且将匹配出的文本作为上下文和用户问题一起添加到提示词中。最后将新的提示词提交到基础 LLM 生成智能运维回答结果。

2.1 通信网络智能运维知识图谱构建

通信网络智能运维知识图谱构建方法如图 2 所示,首先,构建面向通信网络智能运维的专业领域本体,本体是通信网络智能运维知识图谱的概念层;其次,应用本体模型,应用 LLM 提示学习对不同数据源中的知识进行实体和关系抽取,构建实体、关系三元组;最后,将三元组保存在图数据库中,构建通信网络智能运维知识图谱。本文构建的通信网络知识图谱能全面描述通信网络的结构、功能和运行状态,为智能运维提供知识支持。

2.1.1 通信网络智能运维本体构建

通信网络智能运维领域本体中主要包含通信网络硬件信息本体、设备状态信息本体、运维人员信息本体、运维指导信息本体和历史日志信息本体。其中,通信网络硬件信息本体主要包含不同类型的硬件设备(如路由器、交换机、防火墙、服务器、光传输设备和无线设备)和每种设备的详细属性(如型号、厂商、接口类型、性能指标)。本文构建的面向通信网络智能运维领域本体如图 3 所示。设备状态信息本体主要包含设备的运行状态(如在线、离线、故障)、性能指标(如 CPU 利用率、内存使用率、带宽利用率)、故障信息(如故障类型、故障时间、故障原因)、维护记录(如维护时间、维护内容、维护人员)、配置状态(如当前配置、历史配置变更),以及环境条件(如温度、湿度、电源状态)。

运维人员信息本体主要包含个人身份信息(如姓名、工号、联系方式)、专业技能和资质(如证书、培训记录、擅长领域)、工作经验(如工作年限、过往项目、职责范围)、工作记录(如处理的故障、执行的维护任务、绩效评估)、角色和职责(如岗位、权限级别、

负责的设备和系统),以及排班和可用性信息(如工作时间、休假安排)。

运维指导信息本体主要包含操作步骤和流程(如具体操作步骤、标准操作规程)、故障排查指南(如常见故障类型、诊断步

骤、解决方案)、维护计划和日程(如定期检查、维护任务安排)、安全规范(如安全操作规程、应急处理措施)、维护建议(如优化配置、性能提升方法),以及文档和手册(如用户手册、技术白皮书、培训材料)。




图2 通信网络智能运维知识图谱构建方法




图3 面向通信网络智能运维领域本体

历史日志信息本体主要包含事件类型(如故障、维护、配置变更)、事件详情(如具体的操作内容、变化描述)、执行人员信息(如操作人员、维护人员的身份信息)、事件结果(如操作成功、失败及其原因),以及关联记录(如关联的工单、后续处理措施)。

2.1.2 知识抽取及融合

获得通信网络智能运维本体后,还需抽取知识载体中的数据,完成知识图谱的建立。对于文档中的智能运维文本类数据,本文采用LLM进行实体和关系抽取。首先进行数据预处理,包括数据清洗、分词与词性标注,以保证输入数据的质量;其次,对LLM进行提示词学习。基于LLM的知识抽取过程如图4所示。




图4 基于LLM的知识抽取过程

首先,构建通信网络运维领域的知识库,该知识库的数据来源于手册中的术语。其次,根据实体抽取任务构建提示学习模板,使得LLM能够识别实体和关系,提取文本中的关键信息,如设备名称、故障类型、运维人员等。构建面向通信网络智能运维知识图谱实体抽取的提示词模板,具体包含“system”“user”和“assistant”。

“system”用于设定LLM的行为和角色和背景,本文构建的“system”为:

“你是一位通信网络智能运维知识图谱构建专家。你的任务是从用户提供的文本中抽取知识图谱的实体和关系。输出格式必须是三元组(实体1,关系,实体2)。

通信网络运维背景:

1. 领域术语:路由器、基站、光纤、网络流量等。

2. 关系类型:导致、优化、修复、提升、减少等。

3. 输出格式:以结构化三元组形式输出,例如(光缆断裂,导致,网络性能下降)。”

“user”用于输入用户提供具体的文本。“assistant”用于根据“system”和“user”的输入,提供结构化的输出,本文构建的“assistant”如下:

“提取的实体和关系如下:

1. (网络流量异常,引发,丢包)
2. (网络流量异常,引发,性能下降)
3. (运维团队,分析,问题)
4. (问题,来自,核心路由器的故障)”

构建完成提示词模板后,采用GPT-4o进行实体、关系抽取。将GPT-4o模型识别的实体与知识库中的术语进行匹配,查找错误识别的实体。对于错误实体人工通过上下文验证,确保实体与文本内容一致,确保高精度的实体识别结果。

传统的实体关系抽取模型依赖预定义的字典和规则系统,基于LLM的方法则更灵活、便捷。依靠数据预处理和提示词学习,能够有效地实现通信网络运维知识抽取,但仍然存在一定的局限性,例如对专业术语或复杂句式的处理能力较差等。对于专业术语和结构化输出不一致的问题,可以考虑在提示词中注入专业术语的方法提升专业术语的理解能力。例如,对于“故障树分析”这个专业术语,在提示词中加入““故障树分析”是运维中用于诊断系统故障的关键方法,请提取以下文本中的相关实体。”未来也可以通过微调LLM的方式,增强LLM对通信网络运维专业术语的理解能力。对于复杂句式,可以结合句法分析工具,帮助分析句子结构、识别语法关系和依存关系,提升知识抽取准确性。

处理抽取的结果。由于通信网络运维知识抽取时,知识来源于不同的手册或载体,导致抽取出的实体和关系存在重复或冲突等问题,需要整合来自不同数据源的通信网络运维知识,实现知识融合。本文采用Word2Vec算法进行相似度分析,Word2Vec算法将输入的词语转换为词向量,然后计算不同词向量之间的余弦相似度,得到不同中文词组之间的相似性。替换相似度高于阈值的数据,去除重复数据得到最终的结果,实现知识融合,降低数据冗余,确保后续存储到图数据库中数据的唯一性。完成知识融合后,需要将实体和关系构建为知识图谱,存储在图数据库中,以支持后续的查询和分析。对于非文本类的其他数据,如图片、视频、非结构化日志等信息,主要通过人工直接抽取的方法,利用标签或链接作为实例。对于图片和视频信息,通过提取图片路径和名称进行实例抽取。

在获得实体和关系后,采用Neo4j存储数据,完成知识融合。在Neo4j中通信网络智能运维实例以节点的形式储存,并且抽取的实例间的关系通过两节点的连接边形式储存。应用Neo4j数据库还能够解决智能运维过程中大规模添加新增数据的问题,并实现通信网络智能运维知识的推理和查询。

2.1.3 知识图谱实例融合

完成实例抽取后,抽取的通信网络智能运维信息能够转化为结构化和关联的知识信息。利用这些知识能形成相应的知识库,并储存在数据库。本文构建的通信网络智能运维知识图谱

采用 Neo4j 存储数据,Neo4j 是一种高性能的图数据库,在通用知识图谱领域有广泛的应用。Neo4j 能有效存储通信网络智能运维结构数据。在 Neo4j 中通信网络智能运维实例以节点的形式储存,并且抽取的实例间的关系通过两节点的连接边形式储存。




图5 通信网络智能运维知识图谱的实例-关系局部示意图

2.2 基于 LLM 的通信网络智能运维方法

为了实现通信网络智能运维,本文在构建的通信网络智能运维知识图谱的基础上,进一步引入 RAG 技术,以实现通信网络运维智能问答的应用。首先,构建 RAG 知识库,当用户发起查询时,在知识图谱中查询相应的实体和关系,并将返回的实体和关系输入 RAG 知识库中进行近似搜索,找到与查询向量最相似的文本块;其次,将这些文本块与用户问题组合成一个新的提示词,输入生成式 LLM 中;最后,LLM 根据提示词中的上下文信息,生成相应的答案或回复。

2.2.1 通信网络智能运维 RAG 知识库

构建通信网络智能运维 RAG 知识库的过程如图 6 所示,首先收集数据并预处理。通信网络智能运维的数据主要包含通信网络设备、系统日志、用户反馈和历史运维记录等多类文档。获取文档后对文档进行预处理,去除文档中重复、无效和错误数据。其次对文档内的内容进行分块,应用嵌入式模型(embedding 模型)将文本转换为向量保存在向量数据库中。最后在用户问题查询阶段,通过相同 embedding 模型将用户问题转化为向量,在向量数据库中查找与用户问题相关的所有文本块内容,用于后续的结果生成。




图6 RAG 知识库构建流程

在文档解析阶段,由于通信网络运维领域文档的排版方式与常规方式存在较大差异,本文采用 YOLOv9 算法,采集 2000 张通信网络运维手册图片进行内容分块标注,结合文档布局开源数据集,将手册中的标题、图片、文本、表格等内容,在 YOLOv9 算法上进行微调训练,运维手册文档布局检测准确性达到 95%。应用训练好的 YOLOv9 检测文档布局,将检测出的每个区域作为单独的分块进行后续的向量化处理,确保语义的连贯性。

在文本向量化阶段,embedding 模型需要将分块文本转换为向量数据保存在向量数据库中,在知识检索时,同样需要应用 embedding 模型将用户问题转换为向量后进行语义检索。当前主流文本向量化模型主要有 BGE(BAAI General Embedding)、GTE(General Text Embeddings)、M3E(Moka Massive Mixed Embedding)和 BCE(Bilingual and Crosslingual Embedding)模型。选择包含中、英文这 2 种语言的通信运维文档制作测试数据集,包含 50 个问题和正确答案。对所有问题模型检索召回结果,计算平均命中率(Hit Rate)(所有问题中召回结果正确数量除以 50)和平均倒数排名(Mean Reciprocal Rank, MRR)(所有问题排序分数之和除

应用 Neo4j 数据库还能够解决智能运维过程中大规模添加新增数据的问题,并实现通信网络智能运维知识的推理和查询。以分组传送网(Packet Transport Network, PTN)运维为例,得到的通信网络智能运维知识图谱的实例和实例关系如图 5 所示。

以 50)。对于每个问题排序分数计算方法为:结果排序在第 n 位,则该问题分数为 $1/n$,不匹配则分数为 0)。运行硬件为 GeForce RTX 4090 显卡,CPU 的运行内存 64 GB,4 TB 存储空间,测试结果如表 1 所示。

表1 不同嵌入式模型命中率和平均倒数排名结果

模型	Hit Rate/%	MRR/%	耗时/ms
bge-m3-large	78.0	56.37	875
gte-large-zh	50.0	27.61	124
m3e-large	80.0	55.22	932
bce-embedding-base	86.0	60.54	317

从表 1 可以看出,在通信文档应用时 bce-embedding-base 模型在测试数据集中取得了较好的测试结果,它的 Hit Rate 为 86.0%,MRR 为 60.54%,时间消耗为 317 ms,优于 bge-m3-large、m3e-large 模型,但是比 gte-large-zh 运行慢。综合性能和时效性考虑,317 ms 符合本文应用场景需求,本文选择 bce-embedding-base 模型作为文本向量化阶段的 embedding 的基础模型。

由于 bce-embedding-base 模型在通用数据集上训练得到,为了进一步提升模型的准确性,针对通信网络智能运维知识问答场景构建数据集,对 bce-embedding-base 模型进行微调训练。针对通信网络智能运维,构建 5000 条训练数据集进行微调训练,数据集中每条数据包含“query”“pos”和“neg”这 3 个字段。“query”是问题,“pos”是正样本列表,“neg”是负样本列表,最终将数据保存为 jsonl 文件。训练 epoch 数设置为 10(由于数据量较少,设定的训练 epoch 数较小,确保原始模型参数的泛化能力,避免过拟合)。最终微调训练后的 bce-embedding-base 模型,在表 1 测试的问题集中,Hit Rate 为 98.0%,MRR 结果为 76.25%,整体结果相较于原始 bce-embedding-base 模型提升 10 个百分点以上,时效性则与原始 bce-embedding-base 保持一致。

2.2.2 基于知识图谱增强的 LLM 运维智能体

传统 RAG 方法由于缺乏处理全局性问题的能力,直接应用已有的 GraphRAG^[19]无法构建有效面向通信网络智能运维的知识图谱。本文提出基于通信网络智能运维知识图谱增强的 RAG 方法,该方法通过利用通信网络智能运维知识图谱中丰富的经验规则知识,增强 RAG 检索内容的完整性和逻辑性。通过将知识图谱中的实体、关系和属性作为检索内容,输入 LLM 中,使 LLM 能够更好地理解通信网络的上下文和语义信息,从而提高它在智能运维任务中的表现。本文方法如图 7 所示。

本文方法的核心步骤可以分为 3 个主要阶段:问题实体识别与图数据库查询、上下文匹配与处理和 LLM 生成与输出。用户通过输入问题启动整个流程,例如“如何解决基站信号干扰问题?”,采用实体识别技术从用户提示中提取具体的运维问题实体。在本例中,系统识别出“基站信号干扰”作为查询的关键实

体,然后将它作为查询条件,检索图数据库中的相关信息。图数据库包含一个详细的通信网络智能运维知识图谱,其中节点代表不同的运维问题和解决方案,边表示它们之间的关联关系。通过查询图数据库,系统可以找到与识别出的运维问题相关的解决方案和信息。

在获取相关的方案信息后,生成一个提示词感知上下文,将图数据库中的结构化信息转化为可用于 LLM 处理的提示词。例如,系统可能会生成多个短语,如“基站信号干扰可以通过频率调




图7 通信网络智能运维知识图谱增强 RAG 方法

3 实验与结果分析

应用本文方法构建一个包含多种运维问题及其解决方案的数据集。随后,开发相应的系统模块,包括运维问题识别模块、图数据库查询模块、提示词感知上下文生成模块和自然语言生成模块。用户通过电脑端或手机端输入问题,在企业私有云上进行智能运维内容检索和 LLM 智能问答,最后将结果输出到手机端或电脑端,得到智能运维解决方案。

由于本文主要研究 LLM 在专业领域的使用,未对 LLM 进行微调训练。实验时直接使用的 LLM 来自阿里千问平台提供的 Qwen2-72B 模型和算力,本文开发的系统部署在 1 张 GeForce RTX 4090 显卡电脑上,CPU 的运行内存 64 GB、4 TB 存储空间。在 RAG 知识库中上传了 100 个文档,包含 PDF 格式的运维手册 10 本、markdown 格式的运维案例 80 个和 JPG 格式的设备分解图 10 张。

3.1 应用案例分析

运维人员接到机房维护工单后,根据工单内容,运维人员赶到通信机房进行维护操作,在维护过程中运维人员发现 AN5006 设备是首次接触该类型的设备,不知道维修过程中如何安装该设备。运维人员打开本文开发的系统手机端,输入“AN5006 设备如何安装?”的问题,系统根据该问题,快速查找相关知识并进行专业的回复,回复结果如图 8 所示。

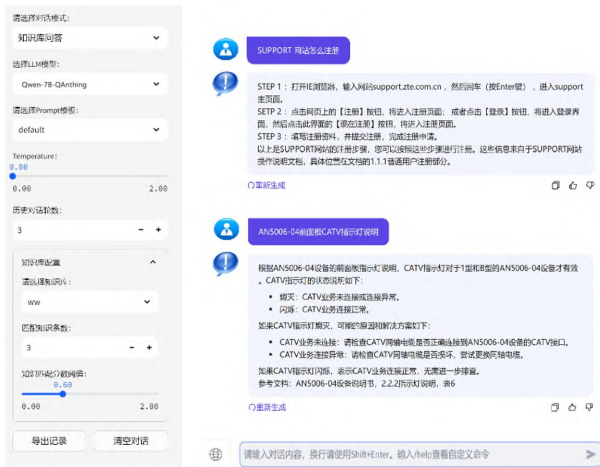


图8 通信网络智能运维知识图谱增强 RAG 智能问答

根据系统回复的结果,运维人员查看系统找到的数据来源,进一步确认回复的准确性。最后,运维人员根据回复的结果按步骤操作,完成 AN5006 设备的安装。本文方法能准确回复型号

整解决”“基站信号干扰可以通过增加滤波器解决”等。这些短语构成了提示词感知上下文。在 RAG 知识库中进行上下文匹配,对比生成的提示词感知上下文与用户的原始问题,以确保提取的信息能够准确地反映用户的查询意图。

最后,系统将匹配到的提示词输入 LLM,通过 LLM 转化为可读的自然语言答案。例如,系统可能输出“解决基站信号干扰问题的方法包括调整频率和增加滤波器。”这一步骤确保了复杂的通信网络运维信息能够以简单、直接的语言传达给用户。

确定的精准性问题,但难以准确回复模糊性问题。在系统使用过程中,运维人员的可以更精细化地提问,从而获得准确的回复。另外,由于系统无法达到 100% 的准确性,只能作为运维人员的辅助工具,提升运维人员的效率和知识水平,无法替代运维人员的工作。

3.2 准确性分析

为了检测本文方法的准确性,针对构建的领域知识运维提供了 200 个问答案例,问题中包含 120 个知识库内的问题、50 个非领域知识库内的问题(即知识库没有该类问题的答案)和 30 个与通信网络无关的通用性问题。对于知识库内的问题需要准确回答操作步骤即为回答正确;对于非领域知识库内的问题需要回答不知道,不能编造答案为回答正确;对于通用性问题可以根据问题内容回答不知道,不能编造答案为回答正确。得到的结果如表 2 所示,表 2 中通用模型是直接使用没有进行微调训练的 bce-embedding-base 模型,微调模型是指使用微调训练的 bce-embedding-base 模型。

通过表 2 可以看出,应用没有进行微调训练的 bce-embedding-base 模型系统的问答综合准确率为 82.5%,针对知识库内的专业知识问答准确率为 84.1%,针对非知识库内的专业问题准确率为 74.0%,针对通用性问题准确率为 90.0%。对于非知识库内的专业问题,LLM 回答存在幻觉现象,导致准确率下降。对于通用问题,系统更容易区分是否知识库内知识,从而进行准确回复。应用微调训练的 bce-embedding-base 模型系统的问答综合准确率为 93.5%,针对知识库内的专业知识问答准确率为 97.5%,针对非知识库内的专业问题准确率为 86.0%,针对通用性问题准确率为 90.0%。

表2 基于知识图谱增强的 LLM 运维智能问答结果

问题	模型	问题总数	正确数	错误数	准确率/%
所有问题	通用模型	200	165	35	82.5
	微调模型		187	13	93.5
知识库内专业问题	通用模型	120	101	19	84.1
	微调模型		117	3	97.5
非知识库内专业问题	通用模型	50	37	13	74.0
	微调模型		43	7	86.0
通用问题	通用模型	30	27	3	90.0
	微调模型		27	3	90.0

本文采用知识图谱的方法进行两阶段的联合智能问答,同时对比 GraphRAG 方法。普通 RAG 方法(即没有使用知识图谱的方法)、GraphRAG 和本文方法进行 RAG 检索回答的准确率对比如表 3 所示。相较于 GraphRAG 和普通 RAG 方法,在所有问题

上,本文方法的准确率提高了17.0和40.5个百分点;在知识库内专业问题上,本文方法的准确率提高了21.7和46.7个百分点;在非知识库内专业问题上,本文方法的准确率分别提高了16.0和40.0个百分点;在通用问题上,本文方法与其他方法差异较小。综合对比结果可以看出,本文构建的面向通信网络智能运维知识图谱相较于通用的 GraphRAG^[19]知识图谱构建方法准确率更高。

表3 不同方法结果对比

问题	模型	问题总数	正确数	错误数	准确率/%
所有问题	本文方法	200	187	13	93.50
	GraphRAG		153	47	76.50
	普通 RAG		106	94	53.00
知识库内专业问题	本文方法	120	117	3	97.50
	GraphRAG		91	29	75.80
	普通 RAG		61	59	50.80
非知识库内专业问题	本文方法	50	43	7	86.00
	GraphRAG		35	15	70.00
	普通 RAG		23	27	46.00
通用问题	本文方法	30	27	3	90.00
	GraphRAG		27	3	90.00
	普通 RAG		26	4	86.70

本文方法在不同 LLM 上也有不同准确率的结果,在仅改变 LLM 的情况下,采用 OpenAI 兼容接口方式在 MiniChat-2-3B、Llama3-8B、ERNIE 4.0 上进行问答测试,结果如图9所示。

由图9可以看出,在同样的知识库和问答内容下,LLM 的基础能力对 RAG 问答的准确性影响较大,MiniChat-2-3B、Llama3-8B 这类参数规模较小的模型准确率明显低于 Qwen2-72B 模型和 ERNIE 4.0。综合来看 Qwen2-72B 取得了最高的准确率,达到93.5%。微调后的 bce-embedding-base 模型对整体问答准确率的影响主要体现在 Qwen2-72B 和 ERNIE 4.0 上,而对于小规模参数的 MiniChat-2-3B、Llama3-8B,微调后的 bce-embedding-base 模型影响较小。未来随着新的 LLM 的出现和 LLM 能力的提升,RAG 的准确率有望进一步提高。由于 MiniChat-2-3B、Llama3-8B、Qwen2-72B、ERNIE 4.0 调用的是不同云平台的 OpenAI,不同 LLM 的耗时缺乏统一硬件进行评价。本文调用 Qwen2-72B 时,采用流式回答,用户问题输入后,系统返回第一个文字的平均时间约为3.5 s,每个问题回复时间根据问题长度而定,平均每百字回复时间约为2.3 s。相较于传统查询手册的方式,基于大语言模型 RAG 方法进行运维知识问答,效率得到极大提升。




图9 不同大语言模型RAG智能问答准确率对比

4 结语

本文提出了基于知识图谱增强的 LLM 辅助通信网络智能运维方法。首先,构建面向通信网络智能运维的知识图谱,考虑了通信网络硬件信息本体、设备状态信息本体、运维人员信息本体、运维指导信息本体和历史日志信息本体之间的规则和关系;其次,构建了面向通信网络智能运维的 LLM RAG 知识库,实现了面向 LLM 智能问答的通信网络智能运维多源多维向量知识库构建;最后,提出一种基于知识图谱增强的 LLM 运维智能体方法,有效利用通信网络知识,提升了通用 LLM 面向专业通信网络智能运维场景问答的准确性。实验结果表明,本文方法具有较好的实用性和有效性。然而,对于模糊或多义性问题,LLM 回答的答案不够准确,在生成答案时也可能出现幻觉或生成准确率不高。针对上述情况,未来可以研究面向通信网络智能运维 RAG

的 LLM 的微调方法,使用更多高质量、标注准确的通信网络智能运维问答数据训练基础 LLM,提升在复杂场景下回复的准确性,减少幻觉。在关键场景中引入人工审核和规则修正,确保输出的答案准确可靠。另外,对于复杂问题的上下文生成和匹配问题、长文本生成等问题,也是未来值得研究的方向。

参考文献 (References)

- [1] 陈嘉悦,庞海舰,裴康,等. 双IRS辅助的NOMA无线携能通信网络优化[J]. 计算机应用研究, 2023, 40(1): 249-256.
- [2] 郭学让,蒋一可,李亚平,等. 持续性灾害下风险感知的光网络业务恢复算法[J]. 光通信研究, 2024(2): 10-15.
- [3] 秦浩,张维石. 基于合作博弈和强化学习的优先信号控制方法[J]. 计算机应用研究, 2024, 41(11): 3350-3356.
- [4] 张颖霖,刘昌辉,黄淑芬. 基于大模型使用方程双重验证提示的数学问题求解[J]. 计算机应用研究, 2024, 41(12): 3729-3734.
- [5] 刘世侠,李卫军,刘雪洋,等. 基于强化学习的知识图谱推理研究综述[J]. 计算机应用研究, 2024, 41(9): 2561-2572.
- [6] LEE Y. Developing a computer-based tutor utilizing Generative Artificial Intelligence (GAI) and Retrieval-Augmented Generation (RAG) [J]. Education and Information Technologies, 2025, 30(6): 7841-7862.
- [7] CIMIANO P, PAULHEIM H. Knowledge graph refinement: a survey of approaches and evaluation methods [J]. Semantic Web, 2016, 8(3): 489-508.
- [8] ZHU J, WANG T, MA X, et al. Deep learning-based knowledge graph construction for three-dimensional design specification of power plant engineering [C]// Proceedings of the 6th International Conference on Big Data Engineering. Piscataway: IEEE, 2024: 118-125.
- [9] LEHMANN J, ISELE R, JAKOB M, et al. DBpedia — a large-scale, multilingual knowledge base extracted from Wikipedia [J]. Semantic Web, 2015, 6(2): 167-195.
- [10] WEI W, CHENG J, CHENG W, et al. TSOKG: a methodology for constructing a telecommunications service operation knowledge graph [C]// Proceedings of the 2024 International Conference on Ubiquitous Computing and Communications. Piscataway: IEEE, 2024: 512-517.
- [11] LI Z, ZHAO Y, LI Y, et al. Fault localization based on knowledge graph in software-defined optical networks [J]. Journal of Lightwave Technology, 2021, 39(13): 4236-4246.
- [12] ZHENG D, SONG X, MA C, et al. DGL-KE: training knowledge graph embeddings at scale [C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 739-748.
- [13] WU J, XU Y, ZHANG Y, et al. TIE: a framework for embedding-based incremental temporal knowledge graph completion [C]// Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 428-437.
- [14] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text Transformer [J]. Journal of Machine Learning Research, 2020, 21: 1-67.
- [15] ISLAM M A, SIDDIQUE H, ZHANG W, et al. A deep neural network-based communication failure prediction scheme in 5G RAN [J]. IEEE Transactions on Network and Service Management, 2022, 20(2): 1140-1152.
- [16] MA Z, CHEN A R, KIM D J, et al. LLMParse: An exploratory study on using large language models for log parsing [C]// Proceedings of the IEEE/ACM 46th International Conference on Software Engineering. New York: ACM, 2024: 1-13.
- [17] WANG D, WANG Y, JIANG X, et al. When large language models meet optical networks: paving the way for automation [J]. Electronics, 2024, 13(13): 2529.
- [18] ALSAIF K M, ALBESHRI A A, KHEMAKHEM M A, et al. Multimodal large language model-based fault detection and diagnosis in context of industry 4.0 [J]. Electronics, 2024, 13(24): 4912.
- [19] EDGE D, TRINH H, CHENG N, et al. From local to global: a graph rag approach to query-focused summarization [EB/OL]. [2024-09-01]. <https://arxiv.org/pdf/2404.16130>.