



电信科学
Telecommunications Science
ISSN 1000-0801, CN 11-2103/TN

《电信科学》网络首发论文

题目：融合大模型与 RAG 技术：证券智能运维助手的应用研究
作者：牟大恩，宋娜，孙丽君
收稿日期：2025-11-18
网络首发日期：2026-01-29
引用格式：牟大恩，宋娜，孙丽君. 融合大模型与 RAG 技术：证券智能运维助手的应用研究[J/OL]. 电信科学. <https://link.cnki.net/urlid/11.2103.TN.20260129.1233.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

融合大模型与 RAG 技术：证券智能运维助手的应用研究

牟大恩^{1,2}, 宋娜², 孙丽君¹

(1. 同济大学计算机科学与技术学院, 上海 200092;

2. 上海证券有限责任公司, 上海 200002)

摘要：在证券行业数字化转型加速的背景下，智能运维已成为保障金融系统稳定性与业务连续性的关键支撑。针对传统运维模式存在的知识孤岛、人工经验依赖强、实时响应能力不足等问题，本文提出一种融合大语言模型与检索增强生成技术的智能运维解决方案。该方案构建了“数据-模型-能力-应用”四层架构：数据层实现多源异构运维数据的标准化治理；模型层依托大模型提供语义理解、逻辑推理与内容生成能力；能力层封装知识管理、知识增强引擎、智能问答、诊断分析及报告生成五大核心模块；应用层通过统一工作台提供知识检索、故障定位、监控预警等运维服务。应用实践表明，该方案有效提升了知识问答准确性、故障定位效率与预警时效性，为证券行业构建安全可控的智能化运维平台提供了可复用的技术框架与实践路径。

关键词：大语言模型；RAG；人工智能；智能诊断；智能运维

中图分类号：TP391

文献标志码：A

文章编号：1000-0801 (XXXX) XX-0001-11

Integrating Large Language Models and RAG Technology: Research on the Application of Intelligent Operations Assistants in Securities

Mou Daen^{1,2}, Song Na², and Sun Lijun¹

1. School of Computer Science and Technology, Tongji University, Shanghai 200092, China;

2. Shanghai Securities Co., LTD, Shanghai 200002, China

Abstract: In the context of accelerating digital transformation in the securities industry, intelligent operational maintenance is recognized as a critical support for ensuring financial system stability and business continuity. To address the shortcomings of traditional operational maintenance models—including knowledge silos, strong reliance on manual experience, and insufficient real-time responsiveness—an intelligent operational maintenance solution integrating large language models with retrieval-augmented generation technology was proposed. A four-tier architecture of "data-model-capability-application" was constructed: the data layer was designed to achieve standardized governance of multi-source heterogeneous operational data; the model layer was equipped with large language models to provide semantic understanding, logical reasoning, and content generation capabilities; the capability layer was encapsulated with five core modules: knowledge management, knowledge enhancement engine, intelligent Q&A, diagnostic analysis, and report generation; and the application layer was implemented through a unified workbench to provide operational services including knowledge retrieval, fault localization, and monitoring and alerting. Practical application demonstrated that the solution effectively enhanced the accuracy of knowledge-based Q&A, the efficiency of fault localization, and the timeliness of alerts,

收稿日期：2025-11-18；修回日期：2026-01-02

通信作者：孙丽君, sunlijun@tongji.edu.cn

基金项目：国家自然科学基金资助项目 (No.62376199)；国家自然科学基金资助项目 (No.62206170)

Foundation Items: The National Natural Science Foundation of China (No.62376199), The National Natural Science Foundation of China (No.62206170)

thereby providing a reusable technical framework and practical pathway for building secure and controllable intelligent operational maintenance platforms in the securities industry.

Key words: Large Language Model; Retrieval-Augmented Generation; Artificial Intelligence; Intelligent Diagnosis; Intelligent Maintenance

0 引言

证券行业作为资本市场的核心基础设施，其业务系统的稳定性与连续性直接关系到市场运行效率与投资者权益。随着业务规模扩张与技术架构迭代，传统依赖人工经验的运维模式逐渐暴露出响应滞后、知识沉淀不足、异常定位效率低等问题。因此，通过智能化手段提升运维效能，已成为保障金融基础设施稳定运行的关键课题^[1]。

近年来，大语言模型（Large Language Model, LLM）在语义理解与内容生成任务中展现出突破性能力^[2]，为众多领域的智能化应用奠定了基础。然而，在证券运维这类专业性强、实时性要求高的场景中，大模型仍面临“幻觉”问题及对静态知识的依赖，可能导致其输出内容偏离事实或无法及时动态响应，限制了其在专业场景的直接应用。检索增强生成（Retrieval-Augmented Generation, RAG）技术通过结合外部知识库检索与生成式模型，为缓解 LLM 的“幻觉”问题提供了有效方案^{[3] [4]}。

本文立足证券行业运维场景特性，提出一种融合 LLM 与 RAG 技术的智能运维助手解决方案。该方案构建了“数据-模型-能力-应用”四层架构，通过分层架构设计实现了从多源知识沉淀到智能决策输出的闭环能力，重点突破了知识动态更新、复杂故障推理、自动化报告生成等运维痛点，为证券行业打造具备自主进化能力的智能化运维平台提供理论支撑与实践参考。

1 相关工作

1.1 研究背景

在当前证券行业的数字化转型浪潮下，信息系统运维正同时面临严峻挑战与深刻机遇。一方面，随着分布式架构、微服务等技术在核心交易、风控等系统中的深度应用，系统架构的复杂度呈指数级增长。证券业务对连续性和实时性要求极高，任何系统异常都可能直接影响市场秩序与投资者权益，这使得保障系统的高稳定性成为金融安全运行的绝对基础。然而，传统以“事后响应”和人工干预为主的被动运维模式已难以适应新形势。行业普遍面临数据驱动能力不足、风险感知滞后、故障应急过度依赖专家个人经验、智能技术应用浮于表面等问题，导致运维响应效率与业务的高实时性要求之间始终存在差距。

近年来，行业在人工智能技术应用于运维领域进行了积极探索，但整体仍处于从“点状尝试”向“体系化应用”过渡的局部阶段。多数机构的实践集中于通过机器学习算法实现基础的时序数据异常检测和告警压缩，或尝试构建知识图谱以辅助根因分析。然而，这些技术应用存在显著局限：一是智能化水平有限，模型多聚焦于特定场景的预测或分类，缺乏对海量、异构的日志、指标、拓扑等多模态运维数据进行融合理解与主动推理的能力；二是知识应用效率低下，宝贵的运维知识（如历史故障案例、应急处置预案）仍以静态文档形式分散存储，难以被系统实时、精准地检索和调用，致使智能决策缺乏可

靠依据；三是人机协同不畅，现有工具多为孤立的数据看板或自动化脚本，未能构建以自然语言为交互界面、贯穿“感知-分析-决策-执行”全链路的智能辅助体系。这些现状导致当前智能运维的潜力尚未完全释放，未能从根本上改变对资深专家经验的深度依赖。

另一方面，监管层面正积极引导行业向数智化、标准化方向转型。例如，中国证券业协会发布的《证券行业信息系统稳定性保障体系标准（征求意见稿）》明确鼓励券商将人工智能（AI）算法、大数据分析 & 大模型等前沿技术深度融入稳定性管理流程，建立数据驱动的运维保障体系。这标志着行业智能运维已进入由监管引领的标准化推进新阶段，也为突破上述技术应用瓶颈指明了明确方向——即建设能够深度融合领域专业知识、具备主动认知与闭环决策能力的下一代智能运维系统。

现有智能化运维方案多聚焦于单点技术优化，例如针对运维场景实现基于时序数据的异常检测^[5]、基于知识图谱的根因分析等^[6]，但仍存在以下局限：

1) 情境理解能力薄弱：传统机器学习模型对非结构化文本（如日志详情、故障报告）的深层语义理解能力不足，难以捕捉运维事件间的复杂关联与上下文；

2) 知识动态集成缺失：通用生成式大模型在专业领域易产生“幻觉”（即事实性错误），且缺乏安全、有效的机制与企业实时更新的私有知识库、操作手册等进行精准结合，导致回答的准确性与时效性不足；

3) 操作流程未能闭环：各类监控、日志、工单等运维工具链相互割裂，导致运维人员仍需在多个系统间手动切换、拼接信息，智能分析的结果无法自动或半自动地转化为可执行的动作，严重影响了故障处置的整体效率与确定性。

1.2 相关技术

大语言模型的发展为解决上述问题提供了新的解决思路^[7]，其通过预训练获得的通用语义理解能力可高效处理运维日志、工单等数据，而 RAG 机制则通过实时接入外部知识库，在增强生成内容准确性的同时，实现企业私有知识的动态融合^{[8] [9]}。

1.2.1 提示工程

提示工程（Prompt Engineering）是指在不更新模型参数的前提下，通过设计输入文本来引导大语言模型生成预期结果的方法。一个完整的 Prompt 需要包含清晰的指示、相关的上下文、有助于理解的示例、明确的输入以及期望的输出格式描述^[10]，Prompt 的构成如下：

1) 指令：明确模型需要执行的特定任务或扮演的角色，如“你是一名证券运维专家，具有丰富的运维经验，请根据以下上下文回答问题”。

2) 上下文：提供与任务相关的背景信息或外部知识，如检索得到的运维文档、监控数据或历史对话记录。

3) 输入数据：清晰标识的用户问题或待处理内容。输入应该在 Prompt 中清晰地标识，以便模型能够准确地识别和处理。

4) 输出指示：指定输出结果的类型或格式，如“以 JSON 格式输出”或“分步骤列出解决方案”。

5) 示例：给出一个或多个具体示例，引导模型理解任务风格与输出结构。

通过上述要素的系统化组合，能够有效引导模型生成符合运维场景要求的专业回答，提升输出的准确性与实用性。

1.2.2 RAG 技术

RAG (Retrieval-Augmented Generation, 检索增强生成)^[11] 是一种结合了信息检索技术与语言生成模型的人工智能技术，在运维场景，RAG 技术可以通过检索外部知识库中的运维案例、系统配置等信息，为大模型提供准确的知识支撑，从而增强其回答的准确性和可靠性^[12]。同时，RAG 可根据用户的查询动态调整检索策略，提高检索效率。

RAG 技术架构主要由检索模块 (Retriever) 和生成模块 (Generator) 组成。检索模块负责从知识库中检索与用户查询相关的信息，通常先将知识库中的文档和用户查询转换为向量表示并存储到向量数据库中，再利向量搜索技术 (如 FAISS、Milvus 等向量数据库) 在向量空间中检索与查询向量最相似的文档或段落，通过计算用户查询向量与知识库文档向量之间的相似度，选择相似度最高的前 k 个文档作为检索结果返回^[13]。生成模块将检索得到的相关文档与查询合并，作为生成大模型的输入，引导大模型基于这些信息生成回答。为了引导大模型生成更符合要求的回答，设计合理的提示模板，向大模型提供额外的上下文信息和领域知识，从而提高其生成的回答质量。

2 智能运维助手系统设计

2.1 智能运维助手总体框架

为解决通用大模型在证券运维专业领域存在的知识局限性，并充分利用企业内部沉淀的海量运维知识文档，本文将大模型和 RAG 技术融合，设计并实现了面向证券运维人员的智能运维助手，其框架如图 1 所示，系统架构自下至上包括数据层、模型层、能力层、应用层。

模型层提供大模型的语义理解、生成和推理等能力。在此基础上，能力层构建运维五大核心能力模块，即知识管理、知识增强引擎、智能知识问答、智能诊断及智能报告生成，覆盖日常维护、变更发布、故障应急、安全管控等多个运维环节。应用层通过统一工作台提供运维服务入口，支持智能知识问答、知识检索、智能诊断分析、智能报告生成等多个场景应用。




图 1 基于大模型+RAG 的证券智能运维助手系统框架图

系统实现核心在于构建基于大模型和 RAG 技术的知识增强引擎，该引擎主要包括知识库构建和知识检索与答案生成等关键环节。基于知识增强引擎这个强大的技术底座，进一步实现智能问答、智能诊断分析及报告生成等场景应用。

2.2 知识增强引擎实现流程

智能运维助手知识增强引擎的整体框架如图 2 所示，主要包括知识库构建和知识检索与答案生成两个阶段。




图 2 智能运维助手流程图

知识库构建阶段包括数据收集、文档解析、文本分块和数据入库。首先，整合运维场景的多源异构数据知识，然后通过文档解析、关键信息抽取、文档分块等技术对原始知识进行标准化处理，接着采用文本向量化模型将知识转为语义向量，最后构建索引后存储到向量数据库内，实现知识的结构化向量表征。

在知识检索与答案生成阶段，首先对用户查询进行标准化和向量化处理，采用关键词检索和向量检索相结合的混合检索策略实现多路召回。在此之上，采用重排序模型结合运维领域特征（如故障等级、处置成功率、操作风险等）对召回结果进行多维度重排序与筛选。最后，通过结构化提示工程将用户查询和筛选后的知识片段输入大模型，引导大模型生成附带溯源引用的专业回答。

2.2.1 知识库构建

2.2.1.1 数据收集

系统汇集证券运维场景所需的多源异构数据，涵盖结构化数据和非结构化数据。其中，结构化数据主要包括配置管理数据库（Configuration Management Database，CMDB）中的资产关系数据、设备监控数据、运维工单数据等。非结构化数据则涉及系统与应用日志、运维知识文档、应急预案文档、历史故障案例、漏洞报告、技术方案、API 接口文档等，其常见格式有 PDF、DOCX、Markdown 等。

数据接入后，经过数据清洗、标注等预处理，系统统一提取并结构化表示文档元数据，形成规范化的数据资产档案，元数据主要字段包括知识库 ID、文档 ID、文件名称、文件类型、文件大小、数据来源、文件格式、数据类型等，具体说明如表 1 所示：

表 1 文档元数据

字段	字段说明	示例数据
----	------	------

kb_id	知识库 ID，标识主题归属	KB_FAULT
file_id	文件 ID，全局唯一	4265
file_name	原始文件名称	数据库服务器磁盘故障处理报告.pdf
file_type	文件格式类型	PDF
file_size	文件大小	1.1MB
file_source	数据来源	告警平台
data_type	业务场景类型	故障案例
title	文件标题	磁盘故障更换与数据恢复报告

2.2.1.2 文档解析

文档解析是知识库构建的基础环节，其提取质量直接影响到下游知识检索和问答准确性。运维文档通常包含多种格式，包括 Word、PDF、Markdown 等，在文档解析时针对不同格式采用不同解析方法以更好的提取文档信息，不同文档的解析策略如表 2 所示。在提取正文内容的同时，着重保留文档内部结构信息（如章节、标题层级），为后续检索分析提供辅助。

表 2 文档解析策略

文档类型	解析方式
PDF	使用 pyPDF2、pdfminer、pdfplumber 和 papermage 等工具提取 PDF 文件内的文本、表格等元数据。对于复杂 PDF，采用 Mineru 进行 OCR 与版面分析。
Word	采用 python-docx 库提取段落、表格、标题结构等信息。
HTML/Markdown	采用 BeautifulSoup 或 markdown 库解析网页和 markdown 文档，保留其语义结构。
代码文档	针对 API 文档、配置文件等，结合语法分析器提取代码注释和代码结构。

2.2.1.3 文本分块

文本分块旨在将长文本内容切分为大小适中的片段（chunks），在保持各片段的语义独立的基础上，提升大模型对文本信息的处理效率与检索准确性。分块策略主要由块大小（chunk size）、块重叠度（chunk overlap）以及分割边界位置三个关键要素决定。常用的文本分块方法包括：固定大小分块（Fixed Size Chunking）、基于句子的分块（Sentence Splitting）、递归分块（Recursive Chunking）、基于文档结构的分块（Document Structure-aware Chunking）及语义分块（Semantic Chunking）等。针对运维文档、故障案例等非结构化文本，本研究采用递归文本分块策略，算法流程如图 3 所示：首先，根据预定义分隔符优先级（例如：换行符>句号/问号/感叹号>分号>逗号）对文本进行初步分割；然后检查各片段长度，若超过设定阈值，则递归调用同一分割过程，并采用下一优先级的分隔符继续分割；上述步

骤，直至所有片段长度符合要求或分隔符列表用尽。最后，在确定块边界时引入块重叠机制，使相邻文本块保留部分重复内容，以确保关键信息的连续性与完整性。




图 3 递归文本分块流程图

在本研究中，块大小设置为 512 个 token，块重叠设置为 64 个 token。该参数设定基于以下考虑：(1) 主流嵌入模型（如 BERT 系列、bge-large-zh-v1.5）的典型输入长度为 512 个 token，该设置可高效利用模型编码容量，降低因截断或填充导致的信息损失；(2) 证券运维文档中，多数语义完整的描述单元如故障现象描述、异常分析、操作步骤等长度普遍落在该范围内，该分块大小有助于保持上下文连贯性，减少跨片段语义割裂。同时，合理设置重叠度能够保证关键上下文信息在相邻块之间得以延续，进一步提升检索与生成任务中的信息完整性。

2.2.1.4 文本向量化与存储

文本向量化与存储是 RAG 技术的关键环节，通过 embedding 模型将文本数据转化为稠密语义向量，并存储在向量数据库中用于下游检索，该环节决定了知识检索的效率和质量。常用 embedding 模型如表 3 所示，根据实际运维场景效果实验，本文选择 bge-large-zh-v1.5 作为文本向量化模型。

表 3 常见 embedding 模型

模型名称	开发者/机构	特点
M3E	MokaAI	采用分层注意力机制和自适应温度采样，在 RAG 场景中召回性能优秀
bge-large-zh-v1.5 ^[14]	智源研究院	针对中文语义匹配进行优化，在 MTEB 等中文基准评测中表现优异，模型参数量适中，推理效率高
nomic-embed-text	Nomic AI	支持 8192tokens 长上下文处理，参数规模小性能优秀，长上下文任务表现优异
GTE ^[15]	阿里巴巴达摩院	基于 BERT 的改进型 Transformer，参数规模小但性能优异，支持细粒度语义匹配。

在存储架构方面，为实现数据持久化、高效检索，本研究采用 Elasticsearch（ES）作为统一的向量与结构化数据的存储方案。证券运维知识库通常包括日志日志、技术文档（PDF/Word/Markdown）、历史故障案例、API 文档等异构数据源，经过解析与分块处理后，通过 bge-large-zh-v1.5 模型转化为统一的语义向量表示并存储于数据库，该向量化过程可形式化表示为：

$$v = E_{\text{bge-large-zh-v1.5}}(t) \in R^d$$

其中 t 表示文本片段, E 表示 embedding 模型, 其将文本片段 t 映射为 d 维稠密向量 v , 本研究中 $d=1024$ 。ES 不仅具备成熟的分布式扩展、近实时检索能力, 其 `dense_vector` 字段类型原生支持高效的近似最近邻 (ANN) 搜索, 同时其倒排索引能力为关键词检索与元数据过滤提供了支持, 满足混合检索策略的需求。本文在 ES 中设计了统一的索引映射来存储向量化后的知识片段, 核心设计如下:

- (1) 语义向量存储: 通过 `q_1024_vec` 字段 (`dense_vector` 类型, 维度 1024) 存储文本语义嵌入, 并采用 HNSW (Hierarchical Navigable Small World) 算法构建索引, 使用余弦相似度作为相似性度量。
- (2) 文本与元数据存储: 每个知识片段对应的原始文本、元数据 (包括 `file_id`、`kb_id`、`file_source`、`chunk_index` 等) 存储在同一个 ES 文档中。元数据字段主要定义为 `keyword` 类型, 设置倒排索引, 支持精确匹配、范围查询与聚合。
- (3) 复合索引结构: 系统构建了多层索引, 倒排索引服务于如 `content_with_weight` 等文本字段的关键词检索 (BM25) 及元数据过滤; 向量索引 (HNSW) 服务于 `q_1024_vec` 字段的语义相似度检索; 元数据字段的倒排索引为二级索引, 实现与向量检索并行的多维度过滤。
- (4) 动态映射: 利用 ES 的动态模板规则, 自动识别并正确映射各类字段, 提升处理多源异构数据模式的灵活性与鲁棒性。。

2.2.2 知识检索与答案生成

2.2.2.1 知识检索

为高效应对证券运维领域复杂多样的查询需求, 本文设计并实现了一种基于 Elasticsearch 的混合检索策略, 旨在融合关键词检索 (Keyword Search) 的精确匹配和向量检索 (Vector Search) 的语义理解能力, 通过对多路检索结果的融合与重排序, 提升检索效能。

本策略的实现基于 Elasticsearch 一体化存储与索引架构, 系统将每个知识片段的稠密向量表示、原始文本内容及结构化元数据封装存储于同一索引文档中, 使得关键词检索可直接利用文本字段上构建的倒排索引实现快速匹配, 向量检索基于向量字段构建的 HNSW 索引执行高效搜索。两种检索方式在统一查询中并行执行, 在保证高召回率的同时, 显著提升检索效率。

关键词检索适用于用户输入明确关键词的查询场景, 如特定错误代码、特定告警信息等。本研究利用 ES 对文本字段的倒排索引与分词能力, 支持基于 BM25 相关性评分算法的全文匹配、布尔逻辑及模糊搜索, 从而实现对运维文档、日志、工单等非结构化数据的快速精准定位。

向量检索采用语义相关度匹配的方式, 本研究基于 embedding 模型 `bge-large-zh-v1.5` 将用户查询和文档内容映射到统一的高维向量空间, 并利用 ES 对 `dense_vector` 字段的原生支持, 构建 HNSW 索引, 采用近似最近邻搜索 (ANN, Approximate Nearest Neighbor Search) 算法、余弦相似度度量, 通过计算用户查询向量与文档向量之间的相似度来召回最相关的 K 个文档返回^[12], 在保证检索准确性的同时, 降低检索时间复杂度。向量检索可以解决词汇不匹配但语义相似的问题, 如用户查询“服务响应慢”可匹配到“API 延迟高”相关的文本内容, 提升长尾问题和复杂描述的检索效果。

本研究将关键词检索的 BM25 分数与向量检索的余弦相似度分数采用加权求和方式计算最终得分，其中权重系数 α 根据查询的语义明确度动态调整，其计算逻辑可表示为：

$$S_{final}(d, q) = \alpha \cdot S_{keyword}(d, q) + (1 - \alpha) \cdot S_{vector}(d, q)$$

其中，表示 $S_{final}(d, q)$ 文档片段 d 对于查询 q 的最终得分， $S_{keyword}$ 和 S_{vector} 分别代表 BM25 分数与余弦相似度， α 为动态权重系数($0 \leq \alpha \leq 1$)，调节两种检索方式的比例。

2.2.2.2 结果重排序

混合检索通过融合不同检索技术优势，实现召回阶段效果的提升。本研究在检索流程后引入重排序模块，对混合检索召回的候选文档进行精细评分与重新排序，从而筛选出相关性最高的文档子集，减少传递给大模型的文档数量，并提高大模型最终生成结果的质量和相关性，如图 4 所示。




图 4 混合检索+重排序策略示意图

本文采用 BGE-Reranker 构建重排模型，计算用户查询与召回的每个候选文档之间的相关性分数，主要流程如下：

- (1) 构造查询-文档对：将用户查询与混合检索返回的每一个候选文档进行配对，构造 $\langle \text{Query}, \text{Document} \rangle$ 。
- (2) 语义相关性评分：BGE-Reranker 对每对 $\langle \text{Query}, \text{Document} \rangle$ 进行联合编码，计算其匹配分数，匹配度为 $[0, 1]$ ，分数越高代表语义相关性越强。
- (3) 动态筛选与排序：根据相关性分数对所有候选文档重新排序，并截取分数最高的 TopK（如 Top5）文档作为最终输入大模型的增强上下文。

经过上述重排序处理，保证了输入到大模型的上下文具备最优的相关性和信息密度，进而增强已有检索效果。

2.2.2.3 答案生成

答案生成旨在将知识检索模块获取的领域知识，与大模型的语义理解与自然语言生成能力相结合，以生成准确、专业、可直接应用的最终答案。该模块的输入包括经重排序筛选的 TopK 篇最相关候选文档片段 $D_{topK} = \{Document_1, Document_2, \dots, Document_K\}$ 以及原始用户查询 Query，其设计遵循以下原则：

- 1) 生成答案必须以提供的参考文档为事实依据，确保所有运维建议、参数配置、操作步骤等均有据可查。
- 2) 答案的格式、语言风格和详细程度需动态适配不同的运维任务类型（如故障排查、配置查询、方案执行等）。
- 3) 关键结论或建议应能关联至源文档，可追溯。

基于上述设计原则，本研究将系统指令、用户查询、相关上下文、领域知识以及输出要求整合，设计了结构化提示词（Prompt）模板，其结构如下：

系统角色与指令：你是一个专业的证券 IT 运维专家，需要根据提供的参考资料，准确、专业解答用户的运维问题。

回答规则：

1. 回答必须基于给定参考资料，不可编造不存在的信息。
2. 若参考资料不足以回答问题，请明确告知“根据现有资料，无法提供完整解决方案”，并指出已知相关信息。
3. 请判断用户问题类型，并严格按照指定的以下一种格式组织答案：【格式选择与具体规范见下文】

用户问题：{Query}

参考资料【以下是相关运维文档片段（按相关性排序）】：{ D_{topK} }

请生成符合上述要求的专业答案。

为满足证券运维场景的多样化需求，本文主要定义以下三种典型的输出格式规范：1）步骤化排查指南：适用于故障诊断与处理场景，要求输出逻辑清晰、可操作的分步骤操作列表。每一步应包含明确的操作动作、预期结果或检查点。2）结构化参数说明：适用于配置查询或性能调优建议场景，要求以 Markdown 表格形式呈现，包含关键参数、当前值、建议值及说明等。3）可执行代码/脚本示例：适用于需具体操作指令或脚本操作的场景，要求输出语法正确、附有必要注释、可直接复制使用的代码块。

以“队列消费延迟高如何解决”这一典型问题为例，模块工作流程如下：

- (1) 输入：用户查询 Query 为“队列消费延迟高如何解决”，以及检索并重排序后的相关文档片段 D_{topK} 。
- (2) 提示词构建：将 Query 和 D_{topK} 填入上述结构化模板，构建完成的 Prompt 核心部分示例如下：

系统角色与指令：……

回答规则：……

用户问题：队列消费延迟高如何解决

参考资料【以下是相关运维文档片段（按相关性排序）】：

[文档 1]《消息中间件优化手册》：常见原因包括消费者组负载不均（需检查分区分配策略与`consumer.assignment.strategy`配置）；消费者处理逻辑阻塞（建议检查消费线程池配置与业务逻辑耗时）；网络延迟（检查 Broker 与 Consumer 间的网络吞吐量与延迟）。

[文档 2]《故障案例库-xxxx》：某次故障性能日志分析显示，观测到 Consumer 的 poll 间隔波动极大，且 GC 日志中存在频繁 Full GC 记录。解决方案包括优化 JVM 堆大小、调整垃圾回收器为 G1，并增加监控告警。

请生成符合上述要求的专业答案。

-
- (3) 模型推理与生成：LLM 接收 Prompt 后，依据其作为“运维专家”的角色，严格依据参考资料与输出格式规范，生成结构化答案。

通过结构化提示设计与场景化输出规范约束，有效约束大模型的生成内容，满足复运维场景下应用需求。

2.3 结构化提示工程设计

为引导大模型准确生成符合证券运维场景需求的专业内容，本文系统地将提示工程应用于运维全场景，设计了一套可复用的、面向任务类型的结构化提示模板，将模糊的自然语言指令转化为可精确解析、包含领域上下文的结构化任务，显著提升了模型输出的可靠性、准确性与实用性。

(1) 任务导向的模板化设计

针对运维工作的核心环节，设计了覆盖知识问答、指标分析、故障诊断、报告生成四类核心任务的提示模板，每种模板均规范了指令、上下文、输入、输出指示与示例五个关键要素，确保了模型行为与预期高度一致。具体设计如下：

① 知识问答模板：适用于概念查询与操作指导。指令明确模型扮演“证券运维专家”角色，要求其严格基于提供的上下文进行回答，并对未知信息如实告知。输出格式要求使用 Markdown 列表或代码块，以增强可读性。

② 指标分析模板：适用于性能数据解读。指令要求模型对给定的时间序列数据（如 CPU 利用率、交易延迟）进行趋势分析、异常点识别与概要总结。输出指示明确要求包含“趋势描述”、“关键发现”与“初步建议”结构化信息。

③ 故障诊断模板：适用于根因定位与处置决策。此为最复杂的模板之一，指令明确要求模型采用“链式思维”推理模式。输出格式强制为 JSON 结构，包含“故障现象”、“可能原因列表”、“根因可能性排序”及“处置建议”等字段，便于下游系统自动解析与执行。

④ 报告生成模板：适用于自动化生成运维报告。指令要求模型基于提供的关键要素信息（如事件列表、性能指标、处置动作），按照“背景-分析-结论-建议”的逻辑框架组织内容，并生成格式规整、语言专业的 Markdown 文档。

(2) 基于上下文的动态填充机制

在推理时，系统将 RAG 模块检索到的相关知识与实时监控数据动态注入模板的上下文部分，为模型提供精准、丰富的决策依据，填充机制具体包括：

① RAG 检索结果注入：系统将混合检索与重排序后得到的 Top-K 知识片段（如历史故障案例、技术手册节选），作为最关键的上下文动态填入提示模板的 {context} 区域。

② 实时监控数据绑定：对于指标分析与故障诊断任务，系统将从监控平台获取的实时数据（如特定网元的当前负载、错误日志片段）格式化后，填入模板的 {metric_data} 区域。

③ 对话历史管理：在多轮交互中，系统通过维护一个上下文窗口，将经过剪裁的、最相关的历史对话记录作为上下文的一部分填入，确保了对话的连贯性与问题理解的深度。

(3) 链式思维引导

对于复杂故障诊断任务场景，在提示设计中深度集成了链式思维引导策略，明确要求模型进行“步骤推理”，从而提升分析的逻辑性与可解释性。在故障诊断模板的指令部分，会明确包含如下要求：

请你按照以下步骤进行推理分析：

第一步：复述与确认 - 准确理解并复述用户描述的故障现象。

第二步：关联分析 - 结合提供的监控指标与知识库案例，列出所有可能的故障原因。

第三步：证据评估 - 对每个可能原因，评估其与现有证据的匹配度，并进行排序。

第四步：结论与建议 - 给出最可能的根因结论，并提供具体的排查步骤或处置建议

3 智能运维助手应用

3.1 智能知识问答

基于大模型与 RAG 技术构建的智能知识问答引擎，为证券运维场景提供全方位的智能问答支持，有效提升证券运维工作的效率和质量。通过自然语言查询方式，为运维人员提供实时技术咨询，及时解答系统配置、参数调优等技术问题；提供智能信息检索，快速定位知识库中的技术文档和操作手册；提供案例智能匹配，自动关联历史相似故障的处理经验。

当用户输入运维问题，首先对输入问题进行意图识别，判断是否需要知识库检索，并利用人工标注的高质量 few-shot 样本优化 prompt 模板，对检索多路召回结果进行重排及过滤，将过滤后的文档片段输入大模型，以提高大模型生成答案的准确性。智能知识问答的功能效果如图 5 所示。



图 5 基于 RAG 框架构建智能运维助手问答功能效果图

3.2 智能诊断分析

基于大模型与 RAG 技术构建的智能知识问答引擎，通过输入故障现象描述或机器监控指标数据，提供历史相似案例、故障原因及解决方案等故障诊断与分析功能。通过接入机器监控指标数据，设计合适的提示词模板，实现复杂模式自动挖掘，识别潜在故障风险。当故障发生时，应用大模型的深度思考及推理能力，结合运维知识库，快速检索相似历史案例，对故障现象原因进行多维分析，生成详细解决方案及操作步骤，辅助支持运维决策。

基于大模型对运维信息的语义理解和知识库中沉淀的历史经验信息，综合运用故障树、因果图等逻辑推理方法，结合上下文信息对故障现象进行解析，从而提供准确故障定位与诊断依据^[16]。如针对交易延迟类问题，该模块自动关联分析数据库性能、网络状况、应用程序日志等信息，快速定位故障环节，生成相应处理方案，缩短故障处理时间，智能运维助手诊断分析模块界面如图 6~8 所示。



图 6 智能运维平台的根因分析功能界面展示图



图 7 智能运维故障预警风险提示




图 8 智能运维日志分析

3.3 智能报告生成

3.3.1 智能分析报告

自动化根因分析流程如图 9 所示，将智能诊断分析中的监控指标及预警结果输入大模型，采用思维链（Chain-of-Thought, CoT）技术指示大模型根据思维链分步骤分析问题，结合提供的系统分析报告参考格式，指示大模型自动生成系统异常分析报告。与此同时，根据监控指标预测结果，利用 RPA 技术自动进行资源配置优化，减少系统响应时间。




图 9 基于大模型的自动化根因分析流程图

3.3.2 智能诊断报告

故障诊断报告生成流程如图 10 所示，基于监控指标和智能诊断分析输出，通过设计合适的提示词模板，结合大模型的内容生成能力生成故障诊断报告。首先，将异常监测及根因分析的结果进行整合，并将这些信息输入到智能知识引擎中，从而得到根因列表分析及根因摘要。接着，结合提示词模板，运用思维链技术来指导大模型按照逻辑步骤分析问题。同时，本研究提供经过人工筛选的 few-shot 样例来构建提示词，以此引导大模型自动化生成格式规整的运维故障诊断报告，为运维故障排查和恢复提供决策支持。




图 10 基于大模型的故障诊断报告生成流程图

3.4 应用效果

在实际运维场景中，融合大模型与 RAG 技术的智能运维助手，为证券行业带来了从“被动响应”到“主动感知”的运维范式跃迁。它通过深度理解系统日志、实时关联多维度数据与动态生成处置策略，显著缩短了故障检测与修复时间，提升了系统可用性，同时有效降低了重复告警与人为操作风险。这不仅直接提高了运维效率与系统韧性，也通过预测性维护与资源优化减少了运维成本，使运维团队得以从重复性工作中解放，聚焦于高价值决策。通过本智能运维平台的应用全面优化了传统运维流程，在运维效率、系统稳定性、智能分析能力及成本控制等方面均取得显著成效，具体如表 4 所示。

表 4 应用效果关键指标

指标类别	具体指标	说明
运维效率	平均故障检测时间（MTTD）	大模型通过日志异常检测与根因分析，可将 MTTD 从小时级缩短至分钟级
	平均故障修复时间（MTTR）	利用故障智能分析与智能决策建议，MTTR 可降低 30%-50%
系统稳定性	重大故障发生率	基于风险预警与主动防御，重大故障次数年同比下降 40%以上
	重复故障率	智能根因归并与知识库构建使重复故障减少 60%
智能分析能力	日志/告警压缩率	通过异常摘要与聚合，无效告警减少 30%-50%
	根因定位准确率	在多维度关联分析下，根因定位准确率提升至 80%以上
	知识库检索效率	自然语言查询知识库，问题匹配准确率提升 40%
成本优化	人力运维成本	自动化与智能辅助减少一线运维人员 30%的重复性工作
	新人培训周期	利用 AI 辅助诊断与案例库，新人独立运维时间缩短 50%

4 结束语

本研究围绕证券行业智能运维的核心需求，探索将大语言模型与 RAG 技术相结合构建智能运维助手。本研究构建的智能运维助手依托运维知识库，提供智能知识问答、智能诊断分析、智能报告生成等功能应用，贯穿运维场景中智能监控、预警、诊断等核心环节，显著提升运维工作人员的工作效率，缩短故障修复时间，在提升运维响应速度、降低人为操作失误率、增强系统鲁棒性等方面展现出一定优势，为证券智能运维提供了技术路径参考。

未来研究将深化技术融合探索，构建全方位运维感知与洞察体系。伴随大模型技术突破与行业数字化转型加速，大模型驱动的智能运维平台将为金融市场稳定提供更坚实的保障。

参考文献：

- [1] 李书.数智运维构筑金融科技发展新基石 [J].中国金融电脑, 2024 (8): 53-55.
- LI S. Building a new cornerstone for fintech development through intelligent and data-driven operations and maintenance [J]. China Financial Computer, 2024 (8): 53 - 55.
- [2] Kaddour J, Harris J, Mozes M, et al. Challenges and applications of large language models [J]. arXiv preprint arXiv: 2307.10169, 2023: 1-72.
- [3] Sun Z, Zang X, Zheng K, et al. Redeeep: Detecting hallucination in retrieval-augmented generation via mechanistic interpretability [J]. arXiv preprint arXiv: 2410.11414, 2024: 1-23.
- [4] ARSLAN M, GHANEM H, MUNAWAR S, et al. A survey on RAG with LLMs [J]. Procedia Computer Science, 2024, 246: 3781 - 3790.
- [5] 肖刚, 卢大鹏, 郑文博, 等. 基于时空图注意力网络的多变量时序数据异常检测方法 [J]. 浙江大学学报 (工学版), 2025, 59 (10): 2134 - 2143.
- XIAO G, LU D P, ZHENG W B, et al. Anomaly detection method for multivariate time series data based on spatio-temporal graph attention network [J]. Journal of Zhejiang University (Engineering Science), 2025, 59 (10): 2134 - 2143.
- [6] 于海洋. 基于异质信息网络的分布式软件故障根因分析与预测的研究与应用 [D]. 安徽大学, 2024. DOI: 10.26917/d.cnki.ganhu.2024:14-18.000863.
- YU H Y. Research and application of root cause analysis and prediction for distributed software faults based on heterogeneous information networks [D]. Hefei: Anhui University, 2024:14-18. DOI: 10.26917/d.cnki.ganhu.2024.000863.
- [7] ZHANG L Z, JIA T, JIA M X, WU Y F, LIU A W, YANG Y, WU Z H, HU X M, YU P, LI Y. A Survey of AIOps in the Era of Large Language Models [J]. ACM Computing Surveys, 2025, 58 (2): 44.
- [8] BARRY M, CAILLAUT G, HALFTERMEYER P, et al. GraphRAG: Leveraging graph-based efficiency to minimize hallucinations in LLM-driven RAG for finance data [C] // Proceedings of the Workshop on Generative AI and Knowledge Graphs (GenAIK). 2025: 54 - 65.
- [9] VITUI A, CHEN T H. Empowering AIOps: Leveraging large language models for IT operations management [EB/OL]. arXiv, 2025:1-11. <https://arxiv.org/abs/2501.12461>.
- [10] LI W, WANG X, LI W, et al. A survey of automatic prompt engineering: An optimization perspective [EB/OL]. arXiv, 2025. <https://arxiv.org/abs/2502.11560>.

- [11] GALAT D, MOLLA-ALIOD D. LLM ensemble for RAG: Role of context length in zero-shot question answering for BioASQ Challenge [EB/OL]. arXiv, 2025. <https://arxiv.org/abs/2509.08596>.
- [12] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey [J]. arXiv preprint arXiv: 2312.10997, 2023, 2:1-26.
- [13] 王昱婷, 陈波, 闫强, 等. 基于问题导向提示学习和多路推理的检索增强生成问答 [J]. 计算机工程与应用, 2025, 61 (12): 120-128.
- WANG Y T, CHEN B, YAN Q, et al. Retrieval-augmented generation question answering based on problem-oriented prompt learning and multi-path reasoning [J]. Computer Engineering and Applications, 2025, 61 (12): 120 - 128.
- [14] Chen J, Xiao S, Zhang P, et al. Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation [J]. arXiv preprint arXiv: 2402.03216, 2024:1-18.
- [15] Li Z, Zhang X, Zhang Y, et al. Towards general text embeddings with multi-stage contrastive learning [J]. arXiv preprint arXiv: 2308.03281, 2023:1-18.
- [16] 林挺婕, 郑玮鹏, 黄培芳. 基于多源数据融合的智能运维研究——以信息系统故障诊断为例 [J]. 中国信息化, 2025, (07): 84-85.
- LIN T J, ZHENG W P, HUANG P F. Research on intelligent operation and maintenance based on multi-source data fusion: A case study of information system fault diagnosis [J]. China Informatization, 2025 (7): 84 - 85.